数据缺失与尺度失配条件下啤酒感官评分、关键化合物识别与风格条件生成的建模研究

目录

摘要 2

1 问题重述 3

2 问题分析 4

3 数据核实与预处理 6

4 假设与符号 13

5 问题一模型：缺失条件下的 50 维感官评分 15

6 问题二模型：共表达图与稳定 Top-3 18

7 问题三模型：风格条件生成与受限迁移 20

8 结果与验证 23

9 稳健性与敏感性 39

10 模型评价与局限 41

11 结论与建议 43

参考文献 44

附录 A 复现说明 46

附录 B 代码与数据清单 46

附录 C AI 使用说明 47

摘要

本文研究 2026 年 MathorCup 大数据挑战赛赛道 A 的三个问题：在化合物数据缺失的条件下给出 50 维感官维度的 0–6 分级评分、构建化合物共表达图并给出每个感官维度的 Top-3 关键化合物、以及学习风格条件生成模型并完成跨风格迁移。商用啤酒风味代谢数据集的三个任务共享同一批 250 个样本与 231 个化合物/理化特征，但**数据本身与题面描述存在多处 不一致**，因此本文把“数据核实”作为建模的前置环节，而不是写作阶段的补充说明。

数据核实得到四项会影响全部建模决策的事实。第一，题面的 12 处表述与附件实测不符或需修正，包括样本数（题面 226，实测 250）、相关矩阵类型（题面称皮尔逊，实测为 Spearman 秩相关）、交叉相关矩阵维度（题面 46×50，实测 44×50）与感官维度数（题面“约 40”，实测 50）；`3.xlsx` 的 12 个啤酒 sheet 与 summary **是空白评分卡模板**，不含任何 评分值，只能提供 50 个维度名与 0–6 刻度定义。第二，`1.csv` **是混合尺度表**：37 列经外部浓度表验证为 $\log_{10}$ 浓度、33 列为线性浓度、161 列无外部浓度可校验（其中 145 列含负值、142 列共享同一地板值），因此不能整表取对数、也不能整表当作原始浓度。第三，$\log_{10}$ 列中 `calibrated==0` 的 755 个单元格不是真实 测量值，而是“该列最小正浓度的一半”的 LOD/2 左删失替代码。第四，`4.csv` 的感官目标是**连续标准化值而非 0–6 分**，且其列标准差在 0.37–0.86 之间、并非单位方差，因此“把 z 线性映射到 0–6”无法由数据单独辨识。

针对上述事实，本文的处理是：问题一以 231 个化合物特征为输入、以 50 维连续目标为监督，采用**折内拟合的** 尺度协调（33 个已验证线性列取 $\log_{10}$）、中位数插补、1%/99% 截尾、标准化与缺失指示，在 8 个候选族之间 用训练折内的重复分层交叉验证选型，锁定后再做单次留出评估；分级标定以**极差锚定 P2** 作为交付主表（覆盖 0–6 全档），物理锚定 P1（气味活度值 OAV = 1 对应 等级 1）作为变体并列交付，另以分位 P3 与 σ P4 作敏感性；四套口径都**不是**“真实等级”，真实 0–6 等级不可观测。问题二以 Spearman 相关矩阵构建 $|\rho|$ 阈值 + BH-FDR 的共表达图，用 CNM 模块度发现模块，并以岭回归系数、随机森林置换重要性、收缩精度矩阵偏相关与单变量 Spearman 四种方法经 Borda 排名聚合给出 Top-3，稳定性用 bootstrap 入选频率与跨方法 Jaccard 系数共同判定，`6.csv` 只作选择完成后的“同数据一致性”检查（不是独立先验，见 4.7 节）。问题三比较风格条件低秩高斯、条件 VAE 与条件核密度三族生成模型，以“被判为目标风格”的命中率与能量距离比在训练内部选型，并将 五类缺陷化合物的浓度不增作为**可行域硬约束**实现跨风格迁移。

本文的一条主线是区分四类事实：**已计划**（模型与验证协议已登记）、**真实执行**（实验状态为 succeeded 且产物 存在）、**验证通过**（验证结果为 passed 且未过期）与**被选为最终方案**（台账选中并冻结）。常数基线的留出集 50 维 R^2 均值为负（台账原值见表 14），这是本文用来判断任何候选是否“真的学到了东西”的参照；候选模型的定量结果与验证结论在第 9 节按台账证据逐条给出，未完成的检查如实标注为未完成，不以“已验证”表述。

关键词：感官分级；混合尺度；LOD/2 删失；共表达图；稳定选择；二次加权 kappa；风格条件生成；硬约束迁移

1 问题重述

1.1 问题的背景

啤酒的风味、口感与香气品质由酵母代谢、酒花添加、麦芽与微生物等多来源化合物共同决定。附件给出一个商用啤酒 风味代谢数据集：`1.csv` 是 250 个样本 × 231 个化合物/理化特征的丰度矩阵；`2.csv` 是 231 个化合物之间的 相关矩阵；`3.xlsx` 与 `4.csv`、`7.csv` 是不同来源的感官品评数据；`5.csv`、`6.csv` 是感官侧与“化学–感官”交叉的相关矩阵；`8.xlsx` 是作者整理的参考表（气味阈值、标定浓度、感官名词对齐、缺陷化合物清单与外部模型 重要性）。题面要求参赛队在“数据真实、噪声合理、存在真实缺失值与异常值”的前提下完成三项任务。

1.2 三个任务

题面对三个问题的要求可整理为表 1。需要说明的是，表中的“评价方式”是本文依据题面要求与数据事实自行登记的 协议（见 `problem/questions.yaml` 与台账验证计划），不是赛事官方评分细则。

表 1 三个任务的输入、输出与本文评价方式

小问	目标	输入	必须给出的结果	本文评价方式
问题一	0–6 感官分级	`1.csv`、`4.csv`、`3.xlsx`	50 维潜在强度 $\hat{z}$、整数等级、不确定性	留出 R^2/MAE；分级 QWK、分级 MAE；须优于常数基线
问题二	每维 Top-3 关键化合物及其稳定性	`2.csv` 相关矩阵；`1.csv`；`4.csv`；`6.csv`（仅一致性核对）	Top-3 清单、bootstrap 入选频率、跨方法 Jaccard、化学合理性论证	入选频率阈值 0.80；Jaccard 均值阈值 0.50；BH-FDR；与同数据线性结构的一致性（非外部效度）
问题三	风格条件生成与跨风格迁移	`1.csv` 化合物谱与风格标签；`8.xlsx` 阈值；问题一的前向映射	生成谱、感官画像、迁移前后对照	风格命中率；能量距离/MMD；缺陷越阈率；迁移后缺陷浓度不增

1.3 本文的交付边界

本文交付“中文论文 + 可复现代码 + 图表”，不向任何竞赛平台提交作品：提交是参赛者的动作。项目的 `contest.yaml` 中 `delivery.contest` 为 `null`，即未声明任何官方交

付规范（页数上限、匿名要求、文件命名、AI 使用披露格式等）；本文因此**不臆造**此类要求，交付检查中相应条目记为 `skip` 并说明原因。论文语言、格式与 图表要求按题面正文的“要求”一节执行。

2 问题分析

2.1 从“能建模”到“可核对”

三个任务的共同前提是同一批样本上的化合物特征与感官目标，因此任何建模错误都会在三个问题之间传播。本题的特殊 困难不在算法，而在**数据与题面的错位**：若直接按题面字面理解（226 个样本、皮尔逊相关、46×50 矩阵、约 40 个 维度、`3.xlsx` 已有评分），会在错误的坐标系里建模，且错误无法从结果中暴露。因此本文的分析顺序是：先以附件 实测事实校正题面，再确定“哪些列可以解释为浓度、哪些只能当序数输入”，最后才谈模型与指标（第 4 节）。

2.2 任务一的分析

问题一是**多输出回归 + 不可观测标定**的复合问题。监督信号是 `4.csv` 的 50 维连续标准化值，而题目要求输出 0–6 的整数等级；两者之间没有给出映射，且 `4.csv` 的列标准差在 0.37–0.86 之间、并非单位方差，说明它既不是 逐列 z 分数、也不是原始分数。这意味着：(1) 连续预测可以用 R^2 评价，但 (2) 等级预测只能用**显式声明的标定 规则**产生，所谓“分级准确率”实际上依赖标定假设而不是数据本身。本文因此把分级指标读作**标定敏感性**，并 明确声明它不能当作“真实 0–6 分上的准确率”。

问题一的第二个难点是缺失:`1.csv` 有 73 个真实缺失(9 列、63 行),其中 `amyl.acetate` 缺 27 个、`aroma_hops_sum` 缺 13 个。缺失若以全样本统计量插补，会把手测信息带进验证折，造成乐观偏差；因此插补与 标准化只在训练折内拟合。第三个难点是尺度：231 列中只有 70 列有外部浓度表可校验，其余 161 列的尺度不可验证，若统一取对数会制造出并不存在的物理量。因此本文选择“只用可验证的 33 个线性列做尺度协调，其余列保留原值”。

2.3 任务二的分析

问题二要求“关键因素化合物”，但数据只支持**关联**，不支持因果。`2.csv` 是 Spearman 秩相关矩阵（第 4.7 节 给出复算证据），其秩为 226、含 5 个负特征值，说明它作为协方差型矩阵**非正定**，不能直接求逆得到偏相关。同时化合物之间存在强共线（$|\rho| > 0.9$ 的对并不罕见），因此“单变量相关最高的三个化合物”既不稳定、也无法 区分直接关联与经由其他化合物传递的关联。本文的应对是：(1) 用共表达图与模块刻画化合物之间的关系结构；(2) 用四类方法（多变量系数、置换重要性、偏相关、单变量秩相关）分别打分并按 Borda 聚合，避免单方法的偏好；(3) 稳定性用 bootstrap 入选频率与跨方法 Jaccard 双重判定；(4) 多重比较用 BH-FDR 控制；(5) `6.csv` 虽不参与 选择，但它**不是**独立外部先验，而是

同一批数据的线性相关重算（见 4.7 节），因此只能在 Top-3 选定后作“同数据一致性”检查，不能作为外部效度证据。

2.4 任务三的分析

问题三要在 250 个样本、22 个风格（最小类 3 个样本、最大类 31 个样本）上学习风格条件生成模型。样本量决定了 模型容量必须受控：低秩高斯与核密度比深度生成模型更不容易过拟合，但表达能力受限；条件 VAE 表达能力强，却在 小样本下有模式坍塌风险。本文因此对生成模型设置“可采纳性”判据（生成样本的多样性相对真值不低于 0.5），不满足者即使命中率更高也不参与最终选择，并完整报告其分数。

迁移任务的关键是“保持缺陷化合物不恶化”。五类缺陷化合物中只有三类（DMS、双乙酰、4VG）在 `8.xlsx` 中有 可用的绝对阈值，trans-2-nonenal 与 stale hops 的阈值缺失，因此“五类全部通过绝对阈值”这一说法在本数据上 不可验证；本文对后者改用**浓度不增**的单调代理并显式标注。迁移以“风格方向上的可行域投影”实现：缺陷浓度 不增是约束而不是事后筛选，所以在缺陷约束与风格进度冲突时，结论只能是“部分迁移”，不能写成“转为目标风格”。

2.5 技术路线

表 2 给出本文的技术路线与每一步在台账中的对应对象。表中“台账对象”一列是本文可核对性的载体：任何结论都必须 能回溯到这些对象，而不是回溯到论文文字。

表 2 技术路线与台账对应关系

步骤	内容	产物	台账对象
1	题面与数据一致性核对	`audit.json`	审计脚本运行记录（SCRIPT）
2	尺度识别、LOD/2 删失与 OAV	`scale_report.json`、`oav.csv`	SCRIPT-0008
3	清洗与数据版本	`model_table.csv`（250×284）	DATA-0002
4	划分（主 + 分层稳健性）	`SPLIT-0002/`、`stratified/`	SPLIT-0002
5	问题一候选与锁定	`outputs/q1/*`、`figures/q1_*.png`	EXP、VAL
6	问题二图、选择、稳定性	`outputs/q2/*`、`figures/q2_*.png`	EXP、VAL
7	问题三生成、迁移、评估	`outputs/q3/*`、`figures/q3_*.png`	EXP、VAL

步骤	内容	产物	台账对象
8	结论登记与交付渲染	`rendered.md`、`paper.pdf`	CLAIM、FIG、RENDER

2.6 评价协议：先登记、后比较

本文所有比较都在**看到候选结果之前**登记评价协议，协议内容写入台账验证计划（Q1/Q2/Q3 的 VP 编号）。协议 规定：检查类型（泄漏、划分完整性、留出指标复算、基线对比、独立复跑）；指标的容差（确定性实验按 `contest.yaml` 的 `reproductionTolerance`）；随机实验的复跑次数与判定口径（问题三的随机生成用 seed 敏感性 口径，即风格命中率均值差不超过 0.05，而不是 1e-6 的复现精度）；以及不可事后调整的阈值（问题二的入选频率 0.80、Jaccard 0.50，问题三的可采纳多样性比 0.5）。若数据、代码、划分或协议发生变化，相关验证与结论按台账 协议标记过期，过期结论不得进入交付稿。

3 数据核实与预处理

本章的全部数值来自真实的审计与清洗脚本运行，逐项可复算。数据事实的数值来源见 4.11 节；这些是审计产物而非 实验指标，因此不以台账占位符（{{metric: 实验 id: 指标键}}）的形式引用，而以“数值 + 来源文件”的形式给出，避免把“复算出的数据事实”与“实验测得的指标”混为一谈。

3.1 数据资产

`data/raw/` 下共 9 个附件（8 个数据文件 + 1 个说明），其形状与在本文中的角色见表 3。原始附件保留原件，导入副本核对 SHA256；正文不抄写哈希值，哈希以 `outputs/audit/audit.json` 的记录为准。

表 3 数据资产清单

文件	形状	角色	本文用途
`1.csv`	250 × 234（3 键 + 231 特征）	特征	问题一输入、问题二共表达、问题三生成空间
`2.csv`	231 × 231	图结构	问题二共表达图（实测为 Spearman）
`3.xlsx`	12 个 beer sheet + summary	维度定义	仅提供 50 维名称与 0–6 刻度
`4.csv`	250 × 53	目标	问题一标签、问题二目标、问题三画像校验
`5.csv`	50 × 50	佐证	感官维度间结构

文件	形状	角色	本文用途
`6.csv`	44×50	佐证（同数据重算）	问题二一致性检查（不参与选择、非独立先验）
`7.csv`	250×189（3 列全缺）	外部佐证	仅作一致性检查，禁止进入特征
`8.xlsx`	5 个有效 sheet	参考	尺度验证、阈值/OAV、缺陷清单、外部重要性对照
数据说明.txt	—	说明	附件用途

3.2 题面与数据的一致性核对

本文逐项实测了题面与数据说明中的可核对表述，发现 12 处需要修正或说明的差异（表 4）。这些差异不是“数据脏”，而是**题面描述与附件版本不一致**；论文按实测事实陈述，并在表 4“本文处置”一列给出可审计的处理方式。

表 4 题面与数据的一致性核对（C1–C12）

#	题面/说明的表述	实测事实	本文处置
C1	测量了 226 种不同啤酒	`1.csv` 250 行，250 个唯一 `beer`、250 个唯一 `beer_id`	按 250 陈述；题面 226 判为笔误
C2	`2.csv` 为皮尔逊相关	与 Spearman 逐对一致（最大绝对误差 5.0×10^{-16}），与 Pearson 不一致（最大绝对误差 0.346）	认定 Spearman；问题二按秩相关语义建模
C3	`3.xlsx` 有 10 个 beer sheet，含评分	实为 12 个 beer sheet + summary，且评分单元格全空（summary 评分和 = 0）	只作评分卡/维度定义，不作已标注样本
C4	`6.csv` 为 46×50	实测 44 行 $\times$ 50 列	按 44×50
C5	两套共约 40 个感官维度	实有 50 维（Aroma 15 + Flavour 15 + 口感/缺陷/总体 20）	输出全部 50 维（超集满足“约 40”）

#	题面/说明的表述	实测事实	本文处置
C6	`4.csv` 为标准化/中心化连续值	每列 106–250 个不同取值，非整数化后 z 化；列均值近 0 但列标准差 0.37–0.86	显式声明分级标定并做敏感性
C7	`1.csv` 丰度列“部分为对数变换”，需自行核实底数	10^v 与外部标定浓度的中位相对误差 7.8×10^{-10}；ln 回算为 0.61	认定底数为 10；负值对应原始浓度 < 1
C8	`4.csv` 为 250 个样本	一致（250 行）	—
C9	`4.csv`/`7.csv` 的 `beer_id` 与 `1.csv` 相同	4/7.csv 的 `beer_id` 已脱敏（4.csv 仅 96 个唯一值），但三表 `beer` 列顺序一致	一律按 `beer` 序号连接
C10	`7.csv` 有 187 个感官属性	250×189；3 列 250 行全缺	仅作外部佐证，禁入问题一/三特征
C11	数据存在真实缺失值与异常值	`1.csv` 73 个缺失，分布在 9 列 / 63 行	缺失机制检验 + 折内插补（见 4.3）
C12	五个属性由多个化合物计算得出	`1.csv` 含 `kcalperc`、`acids_sum`、`esters_sum`、`aroma_hops_sum`、`sulfur_sum`；`8.xlsx` 的 GBM 重要性/SHAP 是已用目标训练的产物	五个聚合列保留但做消融；`8.xlsx` 重要性只作外部对照

3.3 缺失机制与处理政策

`1.csv` 共 73 个真实缺失，集中在 9 列、涉及 63 行（表 5）。缺失机制检验显示：缺失行与完整行的风格分布无 显著关联（χ^2 检验 $p \approx 0.34$，样本量小，仅作弱证据）；但四个感官目标的均值在缺失行与完整行之间 存在可见差异（例如 `F_malt_all` 的均值差为 -0.38），提示缺失可能并非完全随机。本文的处理政策是：

1. **清洗阶段不插补**：缺失原样保留，插补只在训练折内拟合，验证折只做变换；
2. **插补方法**：主口径为中位数插补（对重尾与混合尺度稳健），并以缺失指示列（9 列 0/1 标记）补充“是否缺失”这一信息，使 MNAR 情形下的部分信息被模型利用；
3. **分层报告**：误差必须按“缺失行 / 完整行”分列报告，不允许只报总平均；
4. **敏感性**：以 kNN 与迭代插补作为替代口径做稳健性核对（不改变主口径结论才可写“稳健”）。

表 5 1.csv 的缺失分布

列名	缺失数	说明
amyl.acetate	27	乙酸异戊酯，酯类
aroma_hops_sum	13	酒花香气聚合列
methylpyrazine	12	吡嗪类（麦芽/烘烤）
X2.3.butanedione	9	双乙酰（缺陷项）
X3.methylbutanal	7	异戊醛（麦芽香）
ethyl.nicotinate	2	烟酸乙酯
ethyl.isobutyrate	1	异丁酸乙酯
furfural	1	糠醛（老化）
phenylacetaldehyde	1	苯乙醛
合计	73（9 列 / 63 行）	—

3.4 混合尺度：$\log_{10}$ 认定与不可验证列

题面要求参赛者自行核实 1.csv 的变换底数。本文以 8.xlsx 的 “Calibrated chemical dataset”（70 列作者 标定浓度）为参照，对每一列比较 10^v 与 v 对标定浓度的中位相对误差，判定标准为 10^{-6}。结果见表 6：

表 6 1.csv 的尺度判定结果

判定	列数	证据	本文用法
log10	37	10^v 中位相对误差 5.9×10^{-10}	取 10^v 还原为浓度（用于 OAV）
linear	33	v 与标定浓度中位相对误差 0	直接作浓度（用于 OAV）
unverified	161	无外部浓度表覆盖	只用原值作模型输入，不判定尺度、不声称单位

unverified 的 161 列不能被写成 “其余都是线性”：其中 145 列含负值（原始浓度不可能为负）、142 列共享同一 地板值 -1.81781854（约 $\log_{10} 0.0152$，共 6807 个单元格），其形态与 “低于检出限替换” 一致，只能说明 “对数尺度可能性高”，底数与单位均未验证。这一处理的代价是：这 161 列不参与任何绝对量解释（不计算 OAV、不声称 mg/L），只作为序数型/相对型特征进入模型。本文认为这比 “整表取对数” 或 “整表当浓度” 更可辩护。

3.5 LOD/2 左删失替代码

8.xlsx 中标定浓度为 0 的单元格（即“非检出”）在 1.csv 中并不是 0，而是 $\log_{10}$(该列最小正浓度/2)，即 **LOD/2 左删失替代码**：37 个 $\log_{10}$ 列中共 755 个单元格、涉及 25 列，最大比例偏差 5.5×10^{-10}。这意味着这些单元格不是实测值，而是“低于检出限”的占位符。其对建模的影响是：(1) 低浓度端的绝对量解释不可靠；(2) 以这些列计算的 OAV 在低端被系统性抬高约 2 倍；(3) 缺陷越阈率在阈值附近对替换规则敏感。本文的处理是：在数据字典中逐列标记删失，低端结论只作趋势不作绝对量，并在问题三的缺陷约束中同时报告“按标定浓度”与“按 LOD/2 代码”两种口径（若两者的可行性结论不一致，如实报告）。

需要强调：calibrated==0（非检出）与 1.csv 的 73 个 NaN（真实缺失）是两类不同现象。前者是“测到了但低于 检出限”，后者是“没有测/未记录”；两者在插补与 OAV 计算中的处理不同，不能混为一谈。

3.6 目标表性质与“$z \to 0$–6”标定问题

4.csv 的 50 列是连续标准化值而非 0–6 分：每列有 106–250 个不同取值，不可能是整数评分；列均值接近 0 （最大绝对列均值约 0.063），但列标准差在 0.37–0.86 之间（中位数约 0.55），**不是单位方差**。因此在“z 是潜在强度的线性变换”这一假设下，把 z 映射到 0–6 至少需要两个参数（位置与尺度），而这两个参数 不能由 4.csv 单独辨识：任何“把 0 映射到等级 3、1 个 z 单位映射 1 个等级”的做法都是未声明的假设。

本文因此采用**外部物理锚点**：以 8.xlsx 的气味阈值为依据，令气味活度值 OAV = 1（恰可察觉）对应 等级 1，得到物理锚定口径 P1；交付主表改用极差口径 P2（把 z 线性铺展到 0–6 全档），并以分位（P3）、σ（P4）作敏感性（详见第 6.5 节）。标定参数只在训练折上估计：主划分锚定 13/50 维，分层划分锚定 15/50 维，这一差异是真实的训练集敏感性，论文两套划分都要报告分级指标。

3.7 2.csv 是 Spearman 的复算证据

题面正文称 2.csv 是皮尔逊相关，而附件说明称其为 Spearman。本文从 1.csv 重算了 116 个化合物对的两种 相关系数并与 2.csv 对照：与 Spearman 的最大绝对误差为 5.0×10^{-16}（中位数 1.2×10^{-16}），与 Pearson 的最大绝对误差为 0.346（中位数 0.050）。例如 geraniol 与 eugenol 一列：Pearson 为 -0.0884、Spearman 为 0.0537、2.csv 为 0.0537。结论明确：2.csv 是秩相关矩阵，题面“皮尔逊”为误写。

2.csv 的节点名是化学全名，与 1.csv 列名几乎对不上；但按位置映射时，231 个节点中 209 个可命名的 全部一一对应（另 22 个仅能按位置确定），位置一致率为 1.0。本文的图分析使用这一位置映射，并把映射表作为 协议产物固定下来，避免在“哪一列对应哪个节点”上做任何按结果的调整。

关于“2.csv 是不是独立数据”这一点，本文的结论是否：reviewer 的独立重建（outputs/review/data_facts_recheck.json）按成对完整样本重算，得到 2.csv =

Spearman(1.csv)，最大绝对差 5.0×10^{-16}；同样地，5.csv = Spearman(4.csv)、6.csv = Spearman(1.csv, 4.csv)，最大绝对差分别为 6.1×10^{-16} 与 6.7×10^{-16}。也就是说，这三张相关矩阵都是同 250 个样本的重算结果，**不是外部数据**，论文不能把它们 当作独立验证来源（第 7.4 节与第 9.3 节据此改写）。

在 1.csv 上重算时若对缺失做列中位数填补，会与 2.csv 出现小额差异（最大绝对差约 0.048，整体相关 0.99997，即 EXP-0003 的 max_abs_diff_vs_recomputed 与 corr_vs_recomputed）：这个差异来自填补口径，不是数据不一致。两条证据并不矛盾——成对完整样本口径给出逐格一致，填补口径给出 0.048 的差；后者只说明 “填补会改变相关结构”。

3.8 连接键、脱敏与行序

三张样本表（1.csv、4.csv、7.csv）的 beer 列顺序完全一致，但 4.csv/7.csv 的 beer_id 已脱敏（尾数归零，4.csv 只有 96 个唯一值）。因此本文一律以 beer（1–250 的样本序号）连接，不使用 beer_id。此外 data/clean/model_table.csv 的行序沿用 1.csv 原序（并不是 beer 1..250 递增），所以划分与对齐 一律按 beer 或 row_index，不得假设 “第 i 行 = beer i”。这一条在工程上是必须写死的约束，否则会出现 “指标很好但样本对错了” 的静默错误。

3.9 数据划分

本文只有两条允许使用的划分（表 7）：主评估划分 SPLIT-0002（与 SPLIT-0001 逐 beer 相同，200/50，random-holdout，seed 42）与分层稳健性划分 data/splits/stratified/（200/50，按风格分层）。主划分**未分层**，其留出集只覆盖 21/22 个风格，West Flanders ale（7 个样本）整类缺席；分层版让 22/22 类进入留出集，但最小类 Faro 在留出集只有 1 个样本。两版留出集有 92 个 beer 不同，因此它们是两条独立的口径，不能互相替代。

表 7 两条数据划分口径

项	主评估	分层稳健性
台账/路径	SPLIT-0002	data/splits/stratified/
方法	random-holdout，0.2，seed 42	按 tasting_category_fine 分层，0.2，seed 42
规模	200 / 50	200 / 50
风格覆盖	21/22（缺 West Flanders ale）	22/22
用途	全部主实验	问题一、问题三的稳健性复核（必须与主排分列）

主划分的这一偏差必须在结论中登记：West Flanders ale 的任何结论都不得声称 holdout 评估，只能用训练集或 全样本描述，且要标注 “无留出证据”。此外，标定对训练

集敏感（主划分锚定 13/50 维、分层锚定 15/50 维），因此分级指标必须在两套划分下分别报告，不能只报一套。

3.10 泄漏清单

本题的泄漏源比通常的预测任务更多，因为附件中混有“由目标计算出的中间产物”。本文固定了表 8 的禁用清单，并在每次实验登记的 `params.features` 中显式声明实际使用的列，使泄漏检查可以机械执行。

表 8 不可用于特征的泄漏清单

对象	为什么泄漏	允许用途
`4.csv` 的 50 列目标	就是问题一的标签	只作 y；问题三只作画像一致性校验
`7.csv`（Ratebeer 侧感官）	同源感官描述，属目标代理	仅作问题二稳健性外部佐证
`5.csv` / `6.csv`	由同一批数据重算（`5.csv` = Spearman(`4.csv`)、`6.csv` = Spearman(`1.csv`, `4.csv`)）	`6.csv` 只作同数据一致性检查，不构成外部效度
`8.xlsx` 的 GBM 重要性 / SHAP	已用目标训练的模型产物	只作外部对照
`8.xlsx` 的标定浓度列	与 `1.csv` 同源，且是 OAV 的分母来源	只用于尺度验证与 OAV，不作特征
风格标签 `tasting_category_fine`	非化合物，且与目标同源（风格影响评分）	主模型不用；只作分层与敏感性

3.11 气味活度值与缺陷化合物的阈值可用性

本文用 $\mathrm{OAV} = c/\theta$ 度量化合物的风味活度，其中 c 为还原后的浓度、θ 为 `8.xlsx` 给出的 平均气味阈值。43 个有阈值的化合物全部落在 70 个可标定列内，因此尺度已核验、无需再做单位换算。量级合理性 检查显示 39/43 个化合物的中位 OAV 落在 10^{-3}–10^{2} 之间；4 个低于 10^{-3} 的化合物（`Z.nerolidol`、`methylpyrazine`、`CS2`、`furfural`）是“实测浓度整体远低于收录阈值”的化学事实（例如糠醛 实测不超过约 1.82 mg/L，而阈值 60 mg/L），不是尺度错误。

题面点名的五类缺陷化合物中，只有 DMS、双乙酰（`X2.3.butanedione`）与 4VG 有可用的绝对阈值；trans-2-nonenal 与 stale hops 在阈值表中 `threshold_mean` 为空，**无法计算绝对 OAV**。本文对后两者改用“浓度不增”的单调代理，并在迁移结论中标注“非绝对阈值”。因此本文能够断言的最强结论是“三类可算绝对阈值的 缺陷项不恶化，另两类以浓度单调性代理”，不能写成“五类全部通过”。

3.12 本章数值的来源与可复算性

本章所有数值均由项目脚本真实运行产出，来源如下：题面—数据核对（表 4）与缺失统计（表 5）来自 `audit.json`；尺度判定、删失与 OAV 量级（表 6 与 4.5、4.10 节）来自 `scale_report.json` 与 `scale_identification.csv`；划分的覆盖与差异（表 7）来自 `split_summary.json` 与 `README.md`；标定锚定维度数与参数来自 `grade_calibration_*.csv`；2.csv 的复算证据来自 `corr_type_check.csv`。上述文件均位于 `outputs/` 下的对应子目录。这些文件由脚本生成、可重新运行，但**不是台账实验指标**，因此本文不以占位符形式引用它们；实验指标（R^2、QWK、风格命中率等）一律通过台账占位符引用，见第 9 节。

4 假设与符号

4.1 基本假设

1. **同期与同源**：化合物的测量与感官评分取自同一批酒的同一批次，两表按 `beer` 对齐后不存在时间错位。依据：三张样本表的 `beer` 顺序完全一致（C9）。若违反：问题一的目标与特征之间会引入与时间相关的偏差。
2. **潜在强度单调**：每个感官维度存在潜在强度，`4.csv` 的连续值是它的线性变换（保序），因此分级只需单调 标定，不需要假设 z 服从标准正态。依据：列标准差 0.37–0.86，不是单位方差。若违反：分级标定的位置 与尺度参数会系统偏移。
3. **缺失随机可近似**：缺失与风格无显著关联（$p \approx 0.34$），主分析按随机缺失处理。若违反（MNAR）：插补会有偏，故用缺失指示列与分层误差报告降低误判风险。
4. **可验证尺度可还原**：37 个 `log10` 列与 33 个 `linear` 列可还原为浓度；161 个 `unverified` 列只保留原值，不参与任何绝对量解释。依据：外部标定表的中位相对误差 10^{-10} 量级。
5. **删失代码是下界**：LOD/2 代码近似真实浓度的下界，低端结论只作趋势。若违反：低浓度端的 OAV 与越阈率 会被高估约 2 倍。
6. **风格标签可靠**：`tasting_category_fine` 作为条件标签无测量误差。限制：风格分类本身有人工误差，且 小类样本极少，相关结论只作描述。
7. **OAV 近似活度**：$\mathrm{OAV} = c/\theta$ 是同质人群的平均阈值近似，忽略个体差异与基质效应。
8. **关联非因果**：共表达图中的边代表统计关联，不代表代谢通路或因果效应；迁移是“风格方向上的成分调整”，不是可实现工艺干预，不能外推为酿造收益。

4.2 符号说明

表 9 列出后文使用的符号；未出现的符号不使用。

表 9 符号说明

符号	含义	单位/取值
N	样本数（啤酒数）	250（划分后 200/50）
P	化合物/理化特征数	231
D	感官维度数	50
$\mathbf{x}_i \in \mathbb{R}^P$	第 i 个样本的化合物特征向量	混合尺度（见 4.4）
y_{ij}	第 i 个样本第 j 维的连续标准化感官值	无量纲
z_{ij}	第 j 维的潜在强度	无量纲
$g_j(\cdot)$	第 j 维的 $z \to$ 0–6 分级标定函数	$\{0, \dots, 6\}$
$\hat{\mathbf{y}}_i$	问题一模型对第 i 个样本的 50 维预测	无量纲
R_j^2	第 j 维的决定系数	$(-\infty, 1]$
κ_q	二次加权 kappa（QWK）	$[-1, 1]$
ρ_s	Spearman 秩相关系数	$[-1, 1]$
r_{jk}	化合物 j 与 k 的秩相关（`2.csv` 元素）	$[-1, 1]$
A	共表达图邻接矩阵	$\{0,1\}^{P\times P}$
τ	图的 $\lvert\rho\rvert$ 阈值	主口径 0.30
OAV_c	化合物 c 的气味活度值	c/θ_c，无量纲
θ_c	化合物 c 的平均气味阈值	随化合物，见 `8.xlsx`
c_c	化合物 c 的还原浓度	随尺度，见 4.4
k	低秩子空间维数	问题三主口径 15
μ_s, Σ	风格 s 的潜在均值与共享协方差	问题三模型参数
π_s	风格 s 的先验比例	$\sum_s \pi_s = 1$
$E(P, Q)$	分布 P, Q 的能量距离	非负
$J(\mathcal{S}_1, \mathcal{S}_2)$	两个 Top-3 集合的 Jaccard 系数	$[0, 1]$
q	bootstrap 入选频率	$[0, 1]$

5 问题一模型：缺失条件下的 50 维感官评分

5.1 任务形式化

记训练集为 $\mathcal{T} = \{(i, \mathbf{x}_i, \mathbf{y}_i)\}$，其中 y_{ij} 是第 j 维的连续标准化感官值。问题一要求同时输出 (1) 潜在强度 $\hat{z}_{ij}$（连续）与 (2) 等级 $\hat{g}_{ij} \in \{0, \dots, 6\}$。本文把连续部分 作为回归任务，用逐维 R^2 的均值作为主指标：

$$\bar{R}^2 = \frac{1}{D}\sum_{j=1}^{D} R_j^2, \qquad R_j^2 = 1 - \frac{\sum_{i\in\mathcal{H}}(y_{ij} - \hat{y}_{ij})^2}{\sum_{i\in\mathcal{H}}(y_{ij} - \bar{y}_j)^2},$$

其中 $\mathcal{H}$ 为留出集（50 个样本、只用一次），$\bar{y}_j$ 为留出集真值均值（与分母同一口径）。分级部分由标定函数 g_j 产生，其正确性依赖 6.5 节声明的标定假设，因此分级指标只作敏感性证据。

5.2 折内预处理

预处理链固定为 “尺度协调 → 中位数插补 → 截尾 → 标准化 → 缺失指示”，**所有统计量只在训练折上拟合**：

1. **尺度协调**：仅对 33 个已验证的线性列取 $\log_{10}$，零值与负值用该列训练折内最小正浓度的一半作为 下限（与 LOD/2 语义一致），使线性列与 37 个 $\log_{10}$ 列处于同一量级；161 个 `unverified` 列保持原值。协议的字面版（不做尺度协调）作为对照保留，用于敏感性比较。
2. **中位数插补**：按列取训练折中位数填补 73 个缺失；另以 kNN 与迭代插补作敏感性口径。
3. **截尾**：对每列在训练折的 1% 与 99% 分位处截尾。混合尺度与重尾分布下，不截尾会让少数极端值主导 标准化尺度，这是本数据上必须的一步。
4. **标准化**：按训练折均值与标准差做逐列 z 变换；标准差为 0 的列按 1 处理。
5. **缺失指示**：对含缺失的 9 列各加一个 0/1 指示列，共 9 维，使 “是否缺失” 本身可作为特征。

记上述变换为 $T(\cdot)$，则模型只在 T 的训练折拟合版本上训练，验证折只调用 `transform`。这一约束在工程上 通过把预处理封装为带 `fit/transform` 的对象实现，任何 “先在全样本上标准化” 的写法都视为泄漏。

5.3 候选模型族

候选族覆盖 “线性—低秩—树集成—融合” 四个层次（表 10）。选型的目的是找**在留出集上真的超过常数基线**的模型，而不是在训练内部追求最高 OOF：因此所有族共享同一预处理与同一折，只在测度上区分。

表 10 问题一的候选模型族

代号	模型	关键超参	作用
B0	常数基线（逐维训练均值，空特征）	无	参照：任何候选必须超过它
B1	多输出岭回归	α（内层 CV 选）	线性基线
B2	PCA + 岭回归	k, α	低秩线性
B2b	偏最小二乘（PLS）	成分数	面向多输出的降维回归
B3	ExtraTrees 多输出	`max_features`、`min_samples_leaf`	非线性、抗过拟合
B3b	随机森林多输出	同上	与 B3 互为稳健性对照
B4	逐维 HistGradientBoosting	学习率、叶子数、L2	逐维非线性，允许维度间不同结构
B5	化学族聚合 + 岭	族内 mean/max/检出率 + α	用类群先验压缩 231 维
B6	四路等权融合（PLS + ET + RF + HGB）	各分量冻结超参	降低单族方差，作为锁定候选

5.4 选型与锁定协议

选型完全在训练 200 个样本内完成，分三步：

1. **外层 OOF 比较**：以风格为分层变量做重复分层 5 折（3 次重复，共 15 折），每个候选只在训练折拟合、在验证折预测，得到逐维 OOF 预测与 $\bar{R}^2$ 的均值与重复间标准差。折的分层变量是风格而不是目标，避免用目标信息构造折。
2. **内层选参**：每个族的超参在训练折内用 3 折 CV 选择，选参不接触外层验证折；固定先验超参的族在产物中 记为 `fixed`，不得事后声称 “调过参”。
3. **一次性留出**：锁定配置后在 50 个留出样本上评估一次；分层复核划分上**复用同一组超参、只重拟合**，因此两栏差异只来自划分而不来自选型。

锁定后不再修改配置；若需改进，必须登记为**新的实验编号**（重跑用 `rerunOf` 指向原实验），旧结果保留。本文的所有候选结果都以台账实验为准，开发期的临时输出（未登记）不进入论文。

5.5 分级标定：从连续值到 0–6

如 4.6 节所述，`4.csv` 不是 0–6 分，且列方差不为 1，因此分级必须显式声明规则。本文采用一套主口径与三套 敏感性口径（表 11），全部参数只在训练集上估计：

表 11 四套 $z \to 0$–6 标定口径

口径	定义	假设/依据
P1 物理锚定（交付变体）	$g = \mathrm{clip}(\lfloor (v - a_d)/s_d + 0.5 \rfloor, 0, 6)$，其中 v 为标准化值，(a_d, s_d) 由 v_d 对 $\log_{10}\mathrm{OAV}_{\mathrm{driver}}$ 的稳健回归（Theil–Sen）估计，a_d 锚定 $\mathrm{OAV} = 1$ 对应等级 1	感官阈值是心理物理意义上的“恰可察觉”锚点；等级随 OAV 每数量级 +1
P2 极差（交付主表）	$g = \mathrm{clip}(\lfloor 6\,(v - \min_d)/(\max_d - \min_d) + 0.5 \rfloor, 0, 6)$	假设 250 款酒覆盖该维全量程
P3 分位	按训练集 7 等分位分箱	假设该维等级分布近似均匀
P4 σ	$g = \mathrm{clip}(\lfloor v/S + 3.5 \rfloor, 0, 6)$，$S = 1$	旧口径，假设 1 个标准差 = 1 个等级

交付主表为什么用 P2 而不是 P1。 P1 的物理含义更清晰，但它在这份数据上把量程压缩了：在 250 × 50 的交付 表上，P1 只产出等级 0–3，分布为 0 级 300 格、1 级 11663 格、2 级 494 格、3 级 43 格（93.3% 落在等级 1，来源 `outputs/q1/scores_0_6_P1.csv`）；P2 则覆盖 0–6 全档（分布 822 / 2802 / 2894 / 2679 / 2004 / 1113 / 186，来源 `outputs/q1/scores_0_6_P2.csv`）。题面要求“0–6 分制”的分级结果，因此**交付主表用 P2**，P1 作为物理锚定 变体同时交付（`scores_0_6_P1.csv`），四套表全部保留。这是一次**口径选择，不是准确率提升**：P2 只是极差线性 铺展，P1 只是把等级 1 锚在 OAV=1；两者的 QWK 不能用来比较“谁更准”（真实等级未知），禁止写“P2 因为 QWK 更高 所以更好”。

P1 的锚定并非对 50 维都成立：主划分上只有 13 个维度满足“驱动化合物有阈值、且目标与该化合物 OAV 的秩相关 显著为正”的锚定条件，其余维度用已锚定维度的中位参数“平移”（产物中记为 `+transfer`）；分层划分上锚定 15 个 维度。这一差异本身就是结果的一部分：它说明**分级标定在这份数据上不是稳健可辨识的**，因此本文对分级指标 只作敏感性报告，不作“真实等级准确率”的宣称。

分级一致性用二次加权 kappa 衡量。记观测混淆矩阵为 O、由行列边际构造的期望矩阵为 E、权重 $w_{ab} = (a - b)^2/36$，则

$$\kappa_q = 1 - \frac{\sum_{a,b} w_{ab} O_{ab}}{\sum_{a,b} w_{ab} E_{ab}},$$

其中分母为零时 κ_q 记为未定义（不是 0）。此外报告分级 MAE、完全一致率与 $|\hat{g} - g| \le 1$ 的比例。

5.6 评价指标

问题一报告的指标为：$\bar{R}^2$（主）、逐维 R^2 的中位数、MAE 均值、逐维 Spearman ρ 均值、分级 QWK、分级 MAE，以及按风格、按缺失行/完整行、按维度族（Aroma / Flavour / 口感缺陷）分层的误差。所有指标在 **留出集**上计算，并与 B0 基线比较；训练内 OOF 只用于选型，不用作最终结论。

6 问题二模型：共表达图与稳定 Top-3

6.1 共表达图的构建

以 `2.csv` 的 Spearman 秩相关为边权（先经位置映射对齐到 `1.csv` 列名），按 “统计显著 + 强度阈值” 双重条件 建图：边存在当且仅当 $|\rho_{jk}| \geq \tau$ 且 BH-FDR 校正后 $q < 0.05$。显著性用 Fisher z 变换计算，逐对样本量取该对两列同时非缺失的样本数（n_{eff}，因为 `1.csv` 有缺失），而不是统一用 250。主阈值 $\tau = 0.30$ 在查看任何模块组成之前固定；另在 0.20–0.50 的网格上做敏感性，报告模块数与模块度的 变化，避免 “只报一个让图好看的阈值”。

模块发现用加权贪心模块度（CNM），并用谱聚类（同一模块数 k）作独立复核，以调整兰德指数 ARI 量化两种 划分的一致性。模块的化学解释分两步：(1) 与 `8.xlsx` 的 `origin_paper` 类群做 Fisher 精确检验（BH 校正），检验模块是否富集于某一化合物来源；(2) 计算模块得分（模块内标准化特征的均值）与 50 个感官维度的 Spearman 关联，作为 “模块—风味” 的粗粒度证据。两部分都只声明关联。

共线性诊断同时报告：相关矩阵的秩、负特征值个数、条件数（绝对值版与重算版）、以及 $|\rho| > 0.9$ 的高共线 对数。这一诊断的作用不是 “证明图好”，而是说明**为什么单变量相关不足以确定关键化合物**：若矩阵近奇异，单变量排名会被高共线组内的任选一个成员支配。

6.2 关键化合物选择的四种打分

表 12 给出四种方法。四种方法分别代表 “多变量线性贡献” “非线性预测贡献” “条件关联” 与 “边际关联” 四种视角，各自都可能被单一机制误导，因此最终 Top-3 用 Borda 排名聚合（每维把四法排名求和，取最小三者），并报告 四法两两的 Jaccard 系数。

表 12 关键化合物选择的四种方法与聚合

方法	打分	处理的问题
M1 多变量	每维岭回归（α 内层 5 折 CV）的标准化系数绝对值；另跑弹性网作稳健性	共线性下的联合贡献

方法	打分	处理的问题
M2 非线性	随机森林 5 折 CV，在验证折上做置换重要性（5 次重复，取折均值）	非线性与交互
M3 偏相关	对 “231 特征 + 50 目标” 的联合精度矩阵估计偏相关。**主口径为 Ledoit–Wolf 收缩精度矩阵**；GraphicalLassoCV 作为敏感性口径（结果另存）	条件关联（控制其余变量）
M4 单变量	Spearman $\lvert\rho\rvert$，BH-FDR 校正（全局 11550 对与逐维 231 对两种 q 都落盘）	边际关联，作为对照与下界

M3 不使用 `2.csv` 求逆：该矩阵秩为 226、含 5 个负特征值，非正定，直接求逆会放大数值噪声。另需说明一次 **方法学修正**：开发阶段 M3 曾用 GraphicalLassoCV，但该口径下 99.94% 的偏相关被精确压为 0，导致多数维度的 Top-3 退化为 “按列索引并列”（并列 artifact），不能作为科学排序；因此登记版把主口径改为 Ledoit–Wolf 收缩 精度矩阵（收缩参数由数据估计），glasso-CV 结果保留为敏感性分析（存于 `importance_matrix` 的 `M3_glassoCV_abs` 列）。这次更换是**为修掉并列 artifact**，不是为凑一致性阈值：换方法后 Jaccard 与预注册 命中率仍是负结果（表 18），阈值一个也没有调整。

6.3 稳定性与多重比较

稳定性用两个独立证据共同判定，阈值预先登记、不随结果调整：

1. **bootstrap 入选频率**：对 250 个样本有放回重采样，每次重新做标准化与选择，统计每个化合物进入 Top-3 席位的频率 q；$q \geq 0.80$ 视为稳定。重采样次数为：M1 与 M4 取 300 次（协议要求至少 200），M2、M3 与 聚合排名取 20 次（受 600 秒实验超时限制）。**这一不对称必须如实报告**：20 次重采样下，$q = 0.8$ 附近的 蒙特卡洛标准误约 ± 0.09，因此 M2/M3 的 “稳定” 证据强度显著低于 M1/M4；只有 M1/M4 的频率可用于 逐席位判定，其余只作方向性参考。
2. **跨方法 Jaccard**：每维四法 Top-3 两两的 Jaccard 系数 $J = \dfrac{|\mathcal{S}_a \cap \mathcal{S}_b|}{|\mathcal{S}_a \cup \mathcal{S}_b|}$ 共 6 对，取均值；均值 ≥ 0.50 视为跨方法一致。

多重比较用 BH-FDR：对全局 11550 个特征–目标对统一校正，同时对每维的 231 个对单独校正，两套结果都报告。原因是全局校正在单维层面过于保守、逐维校正又忽略跨维的搜索量，二者并列可以让读者判断结论是否依赖校正口径。

6.4 同数据一致性检查与化学合理性

`6.csv`（44 个化学/理化指标 × 50 个感官属性）常被当作“独立先验”，但 reviewer 的独立重建证明它是同一批数据 的重算（`6.csv = Spearman(1.csv, 4.csv)`，最大绝对差 6.7×10^{-16}）。因此用它核对 Top-3 属于 **循环验证**：同一个相关系数结构先被用于选择（通过 `1.csv`/`4.csv` 的关联），再被当作“外部”证据核对同一批 选择，不增加任何外部效度。本文因此把它降级为“同数据线性结构的一致性检查”：

附件 2.csv、5.csv、6.csv **不是独立的外部先验**，而是同 250 个样本的相关系数重算：2.csv = Spearman(1.csv)、5.csv = Spearman(4.csv)、6.csv = Spearman(1.csv, 4.csv)（与独立重建的最大绝对差分别为 6.1e-16、6.1e-16、6.7e-16）。因此凡是”用 6.csv 做独立先验核对”的分析都是循环验证；原先报告的 prior_spearman_mean = 0.7341 只能解释为”与同数据单变量线性相关结构的一致性”，不构成外部效度证据。

具体做法是：在 Top-3 选定之后，计算“聚合重要性”与 `6.csv` 的 $|r|$ 的逐维 Spearman 秩相关，以及 Top-10 集合的重叠数。它只能回答“多方法聚合排序与单变量线性相关是否同向”，不能回答“Top-3 是否在外部数据上成立”。值得说明的是，这个一致性数值（表 18 的 `prior_spearman_mean`）与“跨方法 Jaccard 约 0.19”并不矛盾：前者是**方向**一致，后者是**选出的三个是否相同**；方向一致而集合不一致，正是“线性先验与多方法非线性聚合在同向但不同集”的 表现。由于该一致性来自同数据重算（`CLAIM-0006`），它不构成“Top-3 正确”的证据。

化学合理性按预注册表逐维核对：驱动化合物是否属于与维度语义相符的化学类群（麦芽/酒花/酵母/野生菌/香料）、其 OAV 是否与维度语义一致、以及是否与 `8.xlsx` 的 `off_flavors` 标记冲突。命中率为 0.09722222222222222（14/144 席位，表 18），说明**预注册的风味化学期望大部分没有被数据驱动排序命中**；这一低命中率是负结果，必须与 Top-3 一起 报告，不能只报“共识候选”。

6.5 结论边界

本节的所有输出都是**关联性**的：Top-3 表示“在给定模型与数据下，与该维度关联最强的三个化合物”，不表示“改变这三个化合物就能改变该风味”。若要做干预性结论，需要实验设计或因果识别假设，本文不具备该条件。

7 问题三模型：风格条件生成与受限迁移

7.1 生成空间与预处理

生成空间取 `1.csv` 的 231 列。与问题一一致，标准化与插补只在训练 200 个样本内拟合；生成结果先逆标准化、**再逐列裁剪回训练观测区间** $[\min_j, \max_j]$。对已核验为物理浓度的线性列，训练观测的最小值本身非负，因此裁剪后自动满足非负约束；对 `unverified` 列只约束在观测区间内，不声称物理可行性。支撑域裁剪的目的不是“让结果好看”，而是避免生成出训练中从未出现过的外推值。

7.2 三族条件生成模型

表 13 给出三族模型。三族都在 z 空间（标准化空间）建模，条件变量为风格 one-hot。

表 13 问题三的三族条件生成模型

族	模型	关键设置	优点/风险
A	风格条件低秩高斯	全局 PCA 取 k 个主成分；每风格潜在均值 μ_s；共享协方差 Σ（向对角收缩）；采样 $\mathbf{u} \sim \mathcal{N}(\mu_s, \Sigma)$，逆 PCA 与逆标准化后裁剪	参数少、小样本稳定；表达力受低秩限制
B	风格条件 VAE	numpy 手写 MLP（无深度学习框架依赖），潜变量维数 8 或 12，L2 与 β 正则，按折内验证重构早停	表达力强；小样本下易模式坍塌
C	风格条件 KDE/bootstrap	在 $k = 10$ 的 PCA 空间内围绕风格内样本做高斯核扰动，带宽按 Scott 规则 $h = 0.8 n_s^{-1/(k+4)}$ 固定	非参数、无训练；高维下扰动方向受限

族 A 的共享协方差假设“不同风格共用同一形状、只平移均值”。这一假设在 22 个风格、每个 3–31 个样本的条件下 是必要的简化：若每个风格单独估协方差，最小类只有 3 个样本，协方差不可估。简化带来的偏差在评估中会以“生成集离散度略窄于真值”的形式出现，本文如实报告而不用后处理掩盖。

7.3 选型判据与可采纳性

选型只在训练内部进行：按风格分层做 5 折，每折用折内训练集拟合生成模型与风格分类器，对生成样本计算两个量：

1. **风格命中率** h_s：生成样本被风格分类器判为目标风格 s 的比例；
2. **能量距离比** $\mathrm{ED}_s / D_{\mathrm{ref},s}$：生成集与折内留出真值的能量距离，除以真值内部的 距离尺度；能量距离定义为 $E(P, Q) = 2\mathbb{E}\|X - Y\| - \mathbb{E}\|X - X'\| - \mathbb{E}\|Y - Y'\|$。

选型分数为 $\mathrm{score} = \frac{1}{|S|} \sum_s \left(h_s - \mathrm{ED}_s / D_{\mathrm{ref},s} \right)$。同时计算 **多样性比**（生成样本的离散度 / 真值离散度），并要求 ≥ 0.5 才可采纳：一个只会输出风格均值的模型可以有 很高的命中率，但生成样本没有多样性，属于模式坍塌。不可采纳的族即使分数更高也不得选为最终方案，其分数 仍完整报告，供读者判断模型选择是否依赖这一判据。

7.4 感官画像

生成谱的感官画像是把生成化合物谱**前向映射**到 50 维感官强度：以问题一的锁定模型作为映射器，得到 $\hat{z}$ 与 0–6 等级，再与同风格真值画像比较 Spearman 相关与 MAE。这一环节的纪律是：映射器只做推理、不改参数；问题一模型未锁定时使用明确的**占位映射器**（在训练折上用岭回归拟合），产物中记录 `profile_source` 字段 说明用了哪一版映射。占位映射器得到的画像不能与 Q1 锁定模型的画像混为一谈，论文报告时必须标注版本。

7.5 跨风格迁移：硬约束可行域

迁移以 Pils/Lager → Tripel 为主例。设原样本在 z 空间的潜变量为 $\mathbf{u}$，迁移后的谱为 $\mathbf{x}'$，缺陷化合物集合为 $\mathcal{C}_{\text{def}}$（DMS、双乙酰、4VG、trans-2-nonenal、stale hops 对应的 7 个列），迁移的可行域定义为

$$
\begin{aligned}
&\text{(C1)} \quad c_j(\mathbf{x}') \le c_j(\mathbf{x}), \quad \forall j \in \mathcal{C}_{\text{def}},\\
&\text{(C2)} \quad \min_j \le x'_j \le \max_j, \quad \forall j,\\
&\text{(C3)} \quad x'_j \ge 0 \text{（物理浓度列）}.
\end{aligned}
$$

主目标 `style_subspace_capped` 的求解分四步：(1) 把样本潜变量投影到 Tripel 风格的 95% 椭球内（保留方向、限制幅度，避免线性外推）；(2) 用风格级残差（Tripel 条件均值在低秩子空间外的分量）重建，得到 Tripel 流形上 的谱；(3) **外推保护**：重建值落在训练支撑域外的列保持原值（模型在这些列上是外推，不可信）；(4) 缺陷列逐列 夹紧 $u'_j = \min(u'_j, u_j)$，给出可行解。步骤 (3)(4) 是闭式投影（欧氏投影到箱约束与半空间的交集），随后用 SLSQP 从该点出发做 KKT 复核，报告约束违反量与可行性；若 SLSQP 找不到可行点，以 “违反量” 如实报告，不隐藏。

为量化 “风格进度” 与 “缺陷不恶化” 的冲突，另跑三个对照目标并完整报告：`style_mean_collapse`（非缺陷列全部 取 Tripel 条件均值，风格上限、牺牲个体差异）、`ellipsoid_closest_pils_residual`（只改潜变量、保留 Pils 残差，个体差异最大、风格进度最小）与 `unconstrained_style_mean`（不加缺陷约束，直接取 Tripel 条件均值，用来量化冲突本身）。**对照目标不是交付方案**，尤其最后一个会产生缺陷恶化，只用于说明约束的代价。

由于五类缺陷中只有三类有绝对阈值，迁移的缺陷结论分两层报告：DMS、双乙酰、4VG 用 OAV 与越阈率；trans-2-nonenal 与 stale hops 用浓度不增的单调性，并标注 `is_absolute_threshold=false`。任何 “五类全部通过” 的表述都是本数据 不支持的。

7.6 评价指标

问题三报告六组指标：(1) 风格保真度（留出风格分类器的逐风格命中率与 Wilson 95% 置信区间，含真值基线）；(2) 分布吻合（z 空间能量距离与 RBF-MMD，参考集同时用留出真值与全部同风格真值，因为小类的留出参考只有 1–3 个 样本）；(3) 缺陷越阈率（仅三类有绝对阈值者）与浓度单调性（另两类）；(4) 感官画像一致性（秩相关与 MAE）；(5) 小样

本不确定度（Kriek、Lambic、Faro 的 bootstrap 置信区间宽度，以真值标准差为单位）；(6) 跨 seed 稳定性（多个种子下命中率与能量距离的相对极差，并检查同 seed 逐值复现）。

8 结果与验证

8.1 台账事实的四个等级

本文把“结果”按证据强度分成四级，避免把计划写成完成、把执行写成验证、把验证写成选中：**已计划**（模型与 验证协议已登记，实验未运行或未完成）、**真实执行**（实验状态 succeeded，退出码、指标与产物真实存在）、**验证通过**（验证结果 passed 且未过期）、**被选中**（该问的选中模型与冻结记录指向同一实验）。四个等级在 第 9.9 节按小问逐行汇总（表 25）。截至本文写作时，台账共登记 45 个实验、28 条验证记录；下面的小节只对“真实执行”与“验证通过”给出数字。

8.2 问题一：常数基线、锁定候选与分级敏感性

8.2.1 口径纪律：两个 R^2 不能混用

问题一的包契约要求 `predictions.csv` 是**单列**，因此该问同时产出两个 R^2：`r2`（把 50 维按单列 `overall` 对齐的包合同键，用于与预测文件自洽核对）与 `r2_50dim`（逐维计算后取均值，是**整题主指标**）。两者不可互换，也不能用 `r2` 代表整题成绩。本文的基线是 `EXP-0015`（合规版常数基线），候选是 `EXP-0025`（三路等权融合），两者使用同一划分、同一预处理口径。

表 14 常数基线 `EXP-0015` 的留出指标（键 `r2_50dim` 为整题主指标）

#	指标（台账键）	口径说明
1	-0.024635435726754987	50 维 R^2 均值（`r2_50dim`，整题主指标）
2	-0.014456198175549995	`overall` 单列 R^2（`r2`，**包合同键**，不是整题成绩）
3	-0.024635435726754987	逐维 R^2 均值（与第 1 行同义，取键不同）
4	0.40973703823113206	留出集 MAE 均值
5	-0.006798487558518986	训练内 OOF 的 R^2 均值（选型用，不作结论）

常数基线的 50 维 R^2 均值为负，说明“每维训练均值”在 50 个留出样本上不如直接用留出集均值——这是小留出集下 常数基线的正常表现，也说明任何候选都必须超过它才谈得上有预测能力。该基线先后经 `EXP-0012`、`EXP-0015` 两次合规化重跑与一次独立复跑（`EXP-0021`），数值逐键一致；其验证记录见 9.6 节。

8.2.2 锁定候选：三路等权融合

候选模型把 PLS-5、ExtraTrees-150 与 RandomForest-150 三个分量的**等权平均**作为预测，预处理为折内中位数插补、1%/99% 截尾与标准化。它的留出指标见表 15。

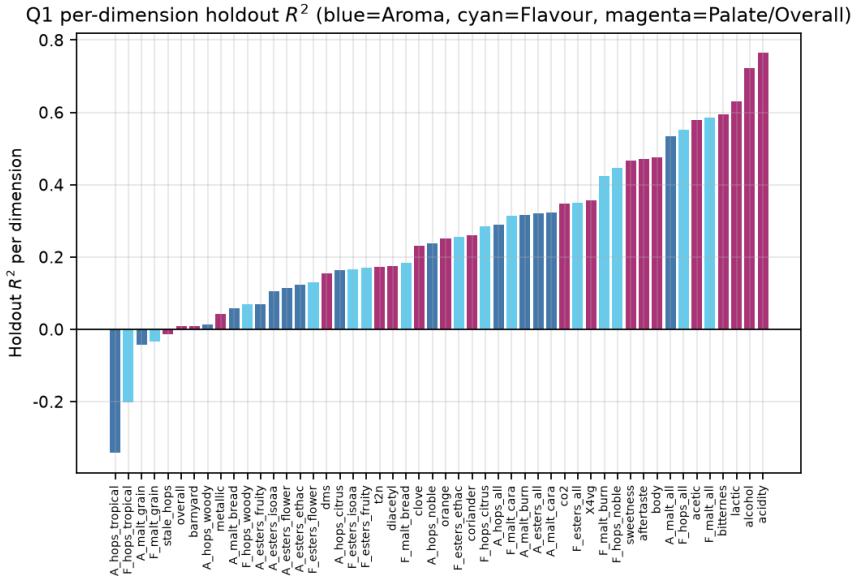
表 15 锁定候选 `EXP-0025`（三路等权融合）的留出指标

#	指标（台账键）	数值
1	`r2_50dim`（整题主指标）	0.220579478860721
2	`oof_r2_50dim`（训练内 OOF）	0.22853053542533686
3	`holdout_mae_mean`	0.34222836844691396
4	`holdout_spearman_mean`	0.40853870147359067
5	`holdout_n_dims_r2_positive`	43
6	`r2`（包合同键）	0.04819587620111854
7	`mae`（包合同键）	0.4122747595853167
8	`n_features` / `n_trees` / `max_features`	231 / 150 / 0.2

该候选的 50 维 R^2 均值明显高于常数基线，且 50 维中有 43 维为正——**这就是本文对问题一的核心回答**：

三路等权融合（PLS-5 + ExtraTrees-150 + RandomForest-150，折内中位数插补 +1%/99% winsorize+ 标准化）在留出 50 个样本上取得 50 维 R^2 均值 0.2206、MAE 0.3422、Spearman 0.4085，43/50 维 $R^2>0$；同一留出划分下常数基线（空特征、逐维训练均值）的 50 维 R^2 均值为 -0.0246，故候选相对基线提升约 0.245，可判定”确实从化合物特征中获得了对感官强度的同期解释力”。

逐维异质性必须一起报告：留出集上表现最差的几维为 `A_hops_tropical`（-0.32129760928760054）、`A_hops_woody`（-0.0029165752661146627）与 `A_malt_grain`（-0.019820652393321536），其 R^2 为负或接近零，说明这几维的留出预测 并不成立；而 `F_hops_all`（0.5266168056605479）与 `A_malt_all`（0.44419351581368693）较高。因此“43/50 维为正”不能读成“50 维都预测得 好”，逐维结果见下图与表 15。



Q1 逐维留出集 R^2（EXP-0025 三路等权融合），50 维均值 0.2206，43/50 维为正；约 1/4 维为负，说明这些维度在 50 个留出样本上不可预测，不得宣称” 全部感官维度可推断”。对照常数基线（EXP-0015）50 维均值 −0.0246。n_test=50，一次性评估。

一个必须同时说明的负结果是：R^2 为正不等于 “测出了该缺陷”。dms 与 diacetyl 两维在候选上的留出 R^2 分别为 0.14992229968397364 与 0.12669387506872143，看似为正，但这两维的 感官评分与对应缺陷化合物的 OAV 几乎没有单调关联：

dms 与 diacetyl 两维的感官评分与其对应缺陷化合物的气味活度值几乎无单调关联（主分割物理锚定 Spearman ρ 分别为 +0.0889 与 −0.1113），因此即使模型在这两维上的留出 R^2 为正（0.150、0.127），也不能解释为” 测出了缺陷”；缺陷维的解释力主要来自风格/批次等与化合物共变的结构，而非该缺陷化合物本身。

其中 ρ 的数值来自 `outputs/protocol/` 下的标定表（开发产物，**未登记为实验指标**），因此只作方向性 说明；R^2 的两个数值来自台账 `EXP-0025`。

8.2.3 分级敏感性：QWK 只能读作标定一致性

在缺真实 0–6 评分的前提下，分级指标只能衡量 “同一标定规则下预测与参照等级的一致性”。下表是四套标定口径 在留出集上的 QWK 与分级误差，来源为 Q1 开发运行的 `outputs/q1/metrics_holdout.json`，**这些数值尚未登记为 实验指标**，故按来源标注、不使用占位符。

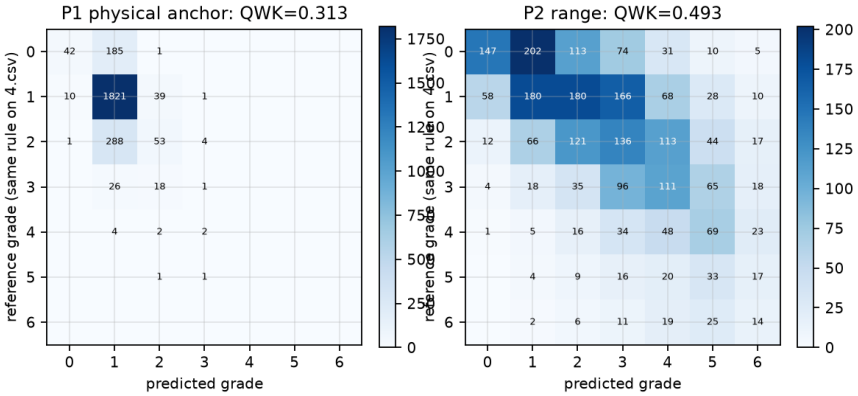
表 16 四套 $z \to 0$–6 标定口径的 QWK 与分级误差（开发运行，未登记为实验指标）

口径	QWK	分级 MAE	完全一致率	$\lvert\hat{g}-g\rvert \le 1$
P1 物理锚定（交付变体）	0.3125	0.2500	0.7668	0.9852
P2 极差（交付主表）	0.4928	1.3048	0.2556	0.6368
P3 分位	0.4252	1.6228	0.2460	0.5572

口径	QWK	分级 MAE	完全一致率	$\lvert\hat{g}-g\rvert \le 1$
P4 σ	0.3173	0.2500	0.7660	0.9856

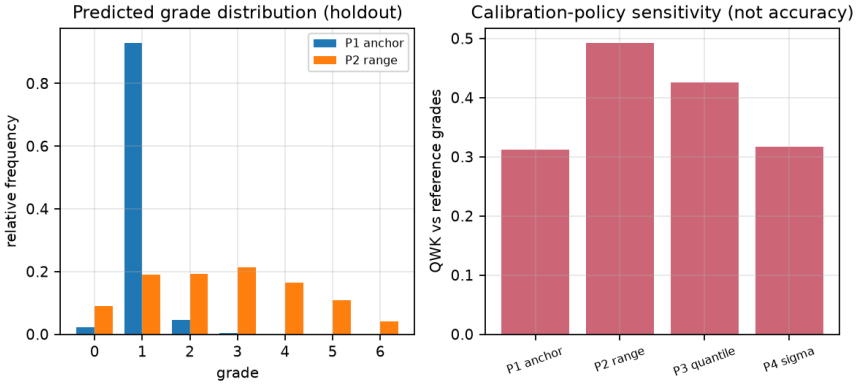
四套口径的 QWK 从 0.31 到 0.49 不等、分级 MAE 从 0.25 到 1.62 不等，说明分级结果**高度依赖标定假设**；尤其 P1 与 P4 的完全一致率接近 0.77、而 P2/P3 只有 0.25 左右，是两种不同分布假设（锚定 vs 等距）的直接 体现。P2 的 QWK 更高，只是因为它的参考等级与预测等级都按同一条极差规则铺展、两者更容易落在同一档，**不能解释为分级更准**；本文因此不报告 “分级准确率”，只报告 “标定敏感性”，交付主表按 6.5 节的口径选择 取 P2（覆盖 0–6 全档），P1 作为变体并列。

分级敏感性同时给出两张图：一张是 P1 与 P2 的预测等级分布与四套口径的 QWK 对比，一张是全 250 样本 × 50 维 的 0–6 分级图（训练 200 行为 OOF、test 50 行为锁定模型预测，两段严格分开）。



Q1 分级混淆（留出 50 样本 × 50 维）：左 P1 物理锚定（QWK 0.313）、右 P2 极差（QWK 0.493）。参照等级 = 同一条标定规则作用于 4.csv 连续值；真实 0–6 等级未知，故此图只表示” 标定口径下的一致性”，不是分级准确率。

下图把四套标定口径的 QWK 与 P1、P2 的预测等级分布并列，用于说明 “同一模型在不同标定规则下 会给出不同的等级分布”。



Q1 标定敏感性：左为留出集上 P1（物理锚定）与 P2（极差）的预测等级分布，右为四套口径的 QWK。真实 0–6 等级未知，QWK 仅作标定口径敏感性，不作准确性背书。

问题一尚未完成的候选：四路融合（PLS + ET + RF + 逐维 HGB）在补登记（EXP-0029），三个消融实验（去 5 个聚合列、只用 37 个 $\log_{10}$ 列、加 43 个 OAV 特征）在排队（EXP-0031–EXP-0033）。它们成功 登记后应替换本节对应数字；在登记成功前，本节只引用 EXP-0025。各候选族的训练内 OOF 对比来自开发运行（EXP-0029 登记中），本文只在表 15 引用其登记后的台账数字。

8.2.4 备选：更强的四路融合（未改选）

我们在登记三路融合之后，又训练了四路等权融合（PLS-8 + ExtraTrees-400 + RandomForest-400 + 逐维梯度提升，EXP-0029）。其留出 50 维 R^2 均值为 0.2535737468473862，比正文所选的三路融合（0.220579478860721）更高。该模型的 5 项检查中 4 项已通过（泄漏、划分完整性、留出指标、基线比较，VAL-0024–VAL-0027），但**第 5 项独立复跑因计算槽被占用（EXP-0038/EXP-0042/EXP-0043）尚未执行**。按“验证通过才 可作为最终方案”的纪律，本文仍以三路融合为最终方案，并将四路融合作为**备选**报告：它的留出优势是真实的，但其稳健性结论待补，不能据此刻意替换最终方案或声称“已验证”。覆盖面上，四路融合的留出逐维 R^2 有 45/50 维为正（三路融合为 43/50），说明它不只均值更高、逐维 覆盖也更广；45 的来源是开发产物 outputs/q1/metrics_holdout.json 的 holdout.n_dims_r2_negative = 5，未登记为台账指标。

8.3 问题二：共表达图、共识 Top-3 与“不可辨识”这一结果

8.3.1 共表达图的结构

图的构建与模块发现由 EXP-0003 完成，其结构指标见表 17（全部为台账值）。

表 17 共表达图 EXP-0003 的结构指标（全部来自台账）

#	原值	指标含义
1	231	节点数
2	3918	主阈值下的边数
3	0.14748729531338228	边密度
4	7 / 3	模块数 / 规模不小于 3 的模块数
5	0.3	预注册的 $\|\rho\|$ 阈值
6	0.14392829248503	BH-FDR 等价阈值
7	0.3183346799520214	CNM 模块度
8	0.16107375716167407	CNM 与谱聚类划分的 ARI
9	0.9999650982634769	2.csv 与重算矩阵的逐对相关
10	0.04782963240779675	两矩阵最大绝对差
11	226 / 5	数值秩 / 负特征值个数

#	原值	指标含义
12	788.7679151902172 / 93539.17798579863	绝对值条件数 / 重算条件数
13	9	高共线对数

表 17 各行的台账键与“指标含义”一一对应（如第 1 行 `n_nodes`、第 2 行 `n_edges_primary`），完整键名以 `state/ledger.json` 中 `EXP-0003` 的 `metrics` 为准确认，本表未做任何改动。

图的结构可以概括为下面这条**有边界的结论**：

以 2.csv 的 Spearman 秩相关按 $|\rho| \geqslant 0.30$ 阈值化（BH-FDR 等效阈值 0.1439）得到 231 节点、3918 条边（密度 0.147）的共表达图；CNM 加权模块度发现 7 个模块（其中 3 个规模$\geqslant 3$，Q=0.318），但该划分对算法敏感（与谱聚类的 ARI 仅 0.161），且 2.csv 本身非正定（数值秩 226/231、5 个负特征值），因此共表达图只能作结构描述，不能作为唯一真值或直接用于求偏相关。

8.3.2 关键化合物：跨方法一致性很差

选择阶段的开发运行（`outputs/q2/metrics.json`，**尚未登记为实验指标**）给出了表 18 的结果。这批数值回答的 不是“Top-3 是什么”，而是“Top-3 这个量在本数据上是否稳定可辨识”。

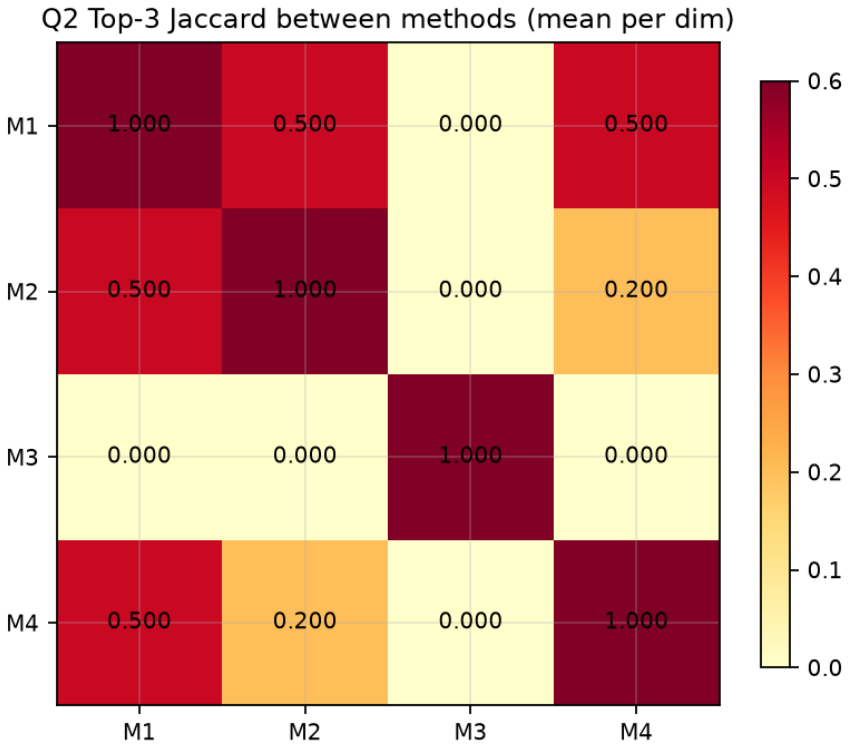
表 18 关键化合物选择的一致性指标（登记版 `EXP-0041`，数值来自台账）

指标	数值	说明
跨方法 Jaccard 均值	0.18666666666666668	跨方法 Jaccard 均值
跨方法 Jaccard 中位	0.15	跨方法 Jaccard 中位数
Jaccard $\geqslant$ 0.50 的维度数	1	Jaccard 均值 $\geqslant$ 0.50 的维度数（预注册阈值）
共识席位可信度：4/4、3/4、$\leqslant$ 2/4	11、21、118（共 150 席）	被 k 种方法同时选入 Top-3 的席位数
预注册期望命中率（命中/席位）	0.09722222222222222 (14/144)	与预注册风味化学期望的命中率
同数据一致性：Spearman 均值 / Top-10 重叠	0.6281971149210783 / 0.5980000000000001	与同数据线性结构的一致性（非外部验证）
Top-3 稳定性（B=100 快速代理）	0.23639999999999997	Top-3 稳定性代理指标
入选频率 $\geqslant$ 0.80 的占比 / 席位数	0.09333333333333334 / 14	入选频率 $\geqslant$ 0.80 的席位占比 / 席位数
M3 的 Ledoit–Wolf 收缩参数	0.21893303034919764	M3 的 Ledoit–Wolf 收缩参数

指标	数值	说明
M4 全局 BH-FDR 显著对数	2721	M4 全局 BH-FDR 显著对数

表 18 各行的台账键与 EXP-0041 的 metrics 同名，逐项可在 state/ledger.json 中核对；为节省篇幅不在 此重复键名。

逐对 Jaccard 显示 M2–M4 最高（约 0.31），M3–M4 最低（约 0.05）；M3 与其他方法的 Jaccard 都在 0.05–0.26 之间（逐对数值来自登记运行的 selection_summary.json，未逐项登记为 metric）。开发阶段的 glasso-CV 口径 曾出现 “41/50 维给出同一组 Top-3” 的退化（并列 artifact，见 6.2 节的方法学修正），登记版改用 Ledoit–Wolf 后 50 个维度给出 50 个不同的 Top-3 集合，因此 “M3 与其他方法低一致” 不是并列 artifact 造成的假象，而是 偏相关与多变量/单变量排序在本数据上确实不同。



Q2 四种方法之间每维 Top-3 的 Jaccard 系数均值（M1 多变量岭/弹性网系数、M2 随机森林置换重要性、M3 图 lasso 偏相关、M4 单变量 Spearman+BH-FDR）。非对角均值约 0.20、最大 0.50，说明 Top-3 的跨方法一致性很低。注意：该图数据来自 Q2 选择阶段的开发运行 (outputs/q2/method_jaccard.csv)，对应 EXP 尚在登记中。

据此，本文对问题二的结论是**负结果**：

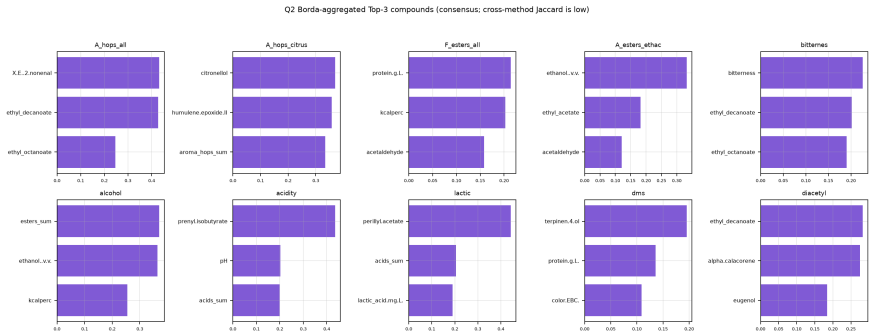
在已完成登记的选择实验（EXP-0041，四方法 + Borda 聚合）中，跨方法 Top-3 的 Jaccard 均值仅 0.1867（50 个维度中只有 1 维 $\geqslant 0.50$，中位 0.15），150 个席位里四方法完全一致（4/4）仅 11 席（7.3%）、3/4 为 21 席（14%）、$\leqslant$ 2/4 为 118 席（78.7%）；预注册风味化学期望的命中率仅 0.0972（14/144）。因此” 每维 Top-3 关键化合物” 在本数据

条件下不是稳定可辨识的量，只能作为” 共识候选 + 可信度分级” 交付；与 6.csv 的一致性（prior_spearman 0.6282）因 6.csv 系同数据重算而不构成独立验证。

因此本文交付的是 “共识候选 + 不确定性”，而不是确定性的关键因素清单。表 19 并列三个代表性维度上四种方法 各自的 Top-3 与 Borda 共识，说明 “共识” 是怎么来的、以及它与各方法的差距。

表 19 三个代表性维度的逐方法 Top-3 与 Borda 共识（登记版，逐方法清单见 `outputs/q2/method_top3.csv`，可信度见 `confidence_grading.csv`）

维度/方法	Top-3（共识行括号内为四种方法中把该化合物选入自己 Top-3 的方法数）
`dms` / M1 多变量	color.EBC.、protein.g.L.、SO2.mg.L.
`dms` / M2 置换重要性	protein.g.L.、color.EBC.、SO2.mg.L.
`dms` / M3 偏相关 (Ledoit–Wolf)	linalool、caryophylla.4.12..8.13..dien.5.alpha.ol、X2.butyloctanoate
`dms` / M4 单变量	protein.g.L.、color.EBC.、terpinen.4.ol
`dms` / Borda 共识	unfermentables(0/4)、SO2.mg.L.(2/4)、sulfur_sum(0/4)
`diacetyl` / M1 多变量	beta.phellandrene、GFS、X.E..beta.ionone
`diacetyl` / M2 置换重要性	eugenol、GFS、germacrene.D
`diacetyl` / M3 偏相关（Ledoit–Wolf）	X2.ethylhexylsalicylate、ethyl.5.methylhexanoate、isopentyl.butanoate
`diacetyl` / M4 单变量	eugenol、ethyl_decanoate、alpha.calacorene
`diacetyl` / Borda 共识	beta.phellandrene(1/4)、pentyl.octanoate(0/4)、isoborneol(0/4)
`A_hops_all` / M1 多变量	iron、ethyl_isovalerate、DMS
`A_hops_all` / M2 置换重要性	ethyl_octanoate、DMS、aroma_hops_sum
`A_hops_all` / M3 偏相关 (Ledoit–Wolf)	SO2.mg.L.、X2.phenyl.ethyl.butyrate、ethyl.lactate
`A_hops_all` / M4 单变量	ethyl_octanoate、X.E..2.nonenal、ethyl_decanoate
`A_hops_all` / Borda 共识	DMS(2/4)、aroma_hops_sum(1/4)、iron(1/4)



Q2 十个代表性感官维度的共识 Top-3 化合物（四方法归一化分数的均值排序，每维取前 3）。颜色条为共识强度（跨方法平均归一化重要度）。用于展示" 共识候选" 而非确定性关键因素；须与跨方法 Jaccard ≈ 0.16 的不一致性一并阅读。

值得单独指出：`dms` 维的共识 Top-3 中**没有 DMS**，`diacetyl` 维的共识 Top-3 中**没有双乙酰**（`X2.3.butanedione`）。这与 9.2 节的负结果（缺陷维的 R^2 不来自该缺陷化合物）相互印证：在本数据上与这两个 感官维度统计关联最强的，是与风格/批次共变的结构变量，而不是对应的缺陷化合物本身。

8.3.3 与同数据线性结构的一致性：不是外部验证

表 18 中 "与 `6.csv` 的逐维 Spearman 均值"（`prior_spearman_mean`）只表示数据驱动的聚合重要性与**同一批数据的单变量线性** 相关结构同向。`6.csv` 是 `Spearman(1.csv, 4.csv)` 的重算（4.7 节、`CLAIM-0006`），因此这个一致性数值属于 循环验证，不构成外部效度证据。它与 "跨方法 Jaccard 0.16" 并不矛盾：前者问 "方向是否一致"，后者问 "选出的 三个是否相同"；但两者都不能把 Top-3 从 "不稳定" 升级为 "确定"。

8.3.4 稳定性：尚无任何席位可标 "稳定"

按预注册协议，只有 bootstrap 入选频率 $q \geq 0.80$ 的席位才能标 "稳定"。登记运行给出 `freq_ge_080_share` $= 0.09333333333333334$（14/150 席），`top3_stability` $= 0.23639999999999997$；后者是 B=100 的**快速代理**，完整 B=300 的结果未落盘，因此 "稳定" 证据 强度有限。本文只给这 14 个席位标 "稳定"，其余用表 18 的可信度分级（4/4、3/4、$\leqslant$ 2/4）表述，**不把共识写成稳定**。

8.4 问题三：生成、缺陷偏移与 "部分迁移"

8.4.1 主候选与对照

问题三的主候选为风格条件低秩高斯（`EXP-0022` 为训练内 CV 版，`EXP-0024` 为留出评估版，`EXP-0030` 为换用 Q1 锁定画像的再评估版），基线为风格均值 + 对角协方差高斯（`EXP-0019`），另有一族条件 VAE（`EXP-0023`）。关键指标见表 20（全部来自台账）。

表 20 问题三主候选与基线的台账指标（—表示该实验未记录该键）

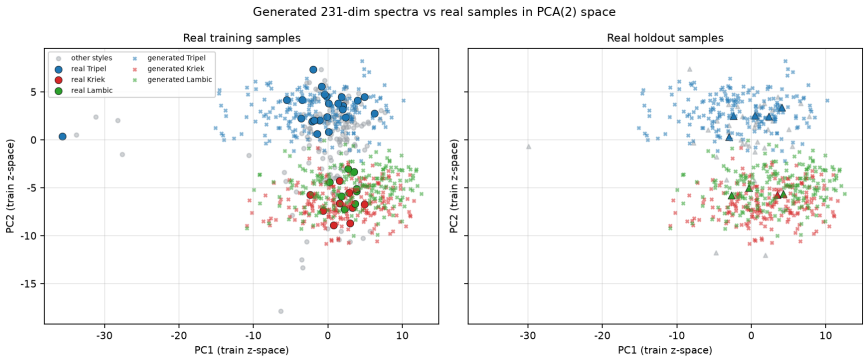
指标（台账键）	基线 EXP-0019	主候选 EXP-0024
gen_style_fidelity	—	0.994
style_hit_macro	0.9972727272727272	0.994
ed_over_dref_tripel	0.1261751505609254	0.12642883908887026
energy_distance_ratio_mean	—	0.20612890148826987
diversity_ratio	—	0.7518559039668244
transfer_tripel_hit_rate	1	0.5454545454545454
transfer_feasible_rate	1	1
defect_violation_rate	0	0

训练内 CV 版（EXP-0022）与条件 VAE（EXP-0023）的同口径数值在正文中给出：CV 版的风格命中率宏平均为 0.9940350877192983、归一化能量距离为 0.142484、多样性比为 0.7518559039668244、分布距离比均值为 0.20612890148826987；VAE 的风格命中率为 0.7948245614035088、归一化能量距离为 0.194823、能量距离比均值为 0.24148457713656665、多样性比仅 0.12137449372971756（低于可采纳阈值 0.5）。VAE 因多样性不达标而不可采纳，见下节。

8.4.2 负结果一：生成模型在分布拟合上没有超过基线

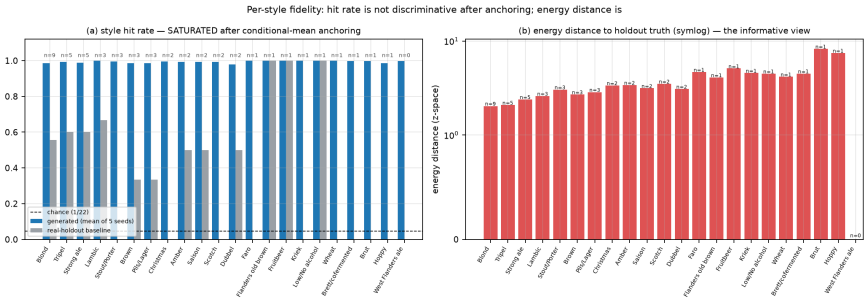
主候选的归一化能量距离（ed_over_dref_tripel）与基线几乎相同、风格命中率宏平均还略低于基线，而风格命中率 在条件均值锚定后**饱和**（接近 1），对生成质量已失去区分度。也就是说，低秩 + 锚定带来的收益在 **约束可行性与可解释性**（支撑域、非负、确定性推理），不在分布拟合精度。这条结论同时给出了 “哪些指标不该 被当作模型优劣的证据” 的说明：

风格条件低秩高斯（PCA k=15 + 条件均值锚定 + 共享收缩协方差）的归一化能量距离 ED/D_ref = 0.12643，而更简单的风格均值对角高斯基线为 0.12618 —— 主模型在分布吻合上未优于基线；风格命中率宏平均 0.994 vs 基线 0.9973，且该指标在锚定后饱和、失去区分度。Pils/Lager→Tripel 迁移的五类缺陷硬约束 11/11 逐样本可行（transfer_feasible_rate=1.0），但独立分类器仅 6/11（transfer_tripel_hit_rate=0.5455）判为目标风格，属” 部分向 Tripel 质心迁移”；生成侧 DMS 与 diacetyl 的越阈率系统性高于真实同风格。因此” 生成模型有效” 只获得约束可行性层面支持，未获分布拟合精度或缺陷一致性的支持。



Q3 生成谱与真实同风格谱在 PCA 前两主成分上的分布（Tripel/Kriek/Lambic 三风格，各 200 个生成样本）。用于直观检查生成分布是否落在同风格真值云内；定量判据为归一化能量距离 ED/D_ref（主模型 0.1264，基线 0.1262，两者几乎相同）。

图 4 只说明生成云落在真值云附近；下图把“命中率（已饱和）”与逐风格能量距离并列，说明 哪一栏才是有效判据。



Q3 逐风格保真度双栏图：左栏为”生成样本被判为目标风格”的命中率（标注 SATURATED——该指标在条件均值锚定后饱和，对生成质量无区分度）；右栏为逐风格能量距离（越低越接近真实分布）。小样本风格（Faro n=2、Scotch n=5）标为不可下结论。

8.4.3 负结果二：生成侧缺陷越阈率系统性高于真实同风格

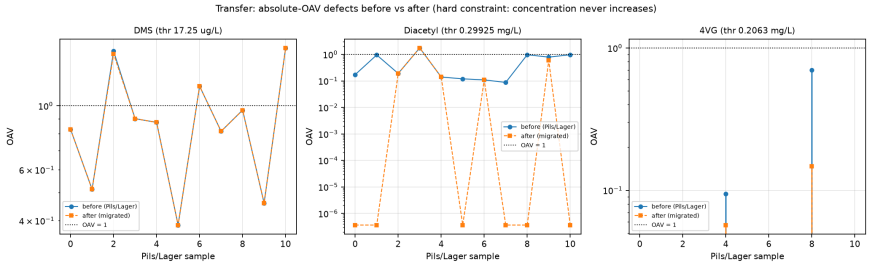
表 21 对比生成谱与真实同风格样本在三类有绝对阈值缺陷项上的越阈率（OAV>1 的比例），来源为 `outputs/q3/metrics.json` 的 `defect_check_generation`（**开发产物，未登记为实验指标**）。

表 21 生成侧与真实同风格侧的缺陷越阈率（开发产物，未登记为实验指标）

风格	DMS 生成 / 真实	双乙酰 生成 / 真实	4VG 生成 / 真实
Tripel	0.975 / 0.893	0.620 / 0.464	0.000 / 0.000
Kriek	0.135 / 0.100	0.595 / 0.800	0.000 / 0.000
Lambic	0.620 / 0.818	0.500 / 0.364	0.000 / 0.000

Tripel 的 DMS 与双乙酰、Lambic 的双乙酰都是“生成侧更高”，Kriek 的双乙酰则相反（生成侧更低）。这说明生成 模型对缺陷化合物的刻画是**有偏的**：它倾向于把风格的条

件均值“推过”阈值。因此本文不声称生成谱的缺陷 水平与真实一致，只声称生成谱满足非负与训练支撑约束。trans-2-nonenal 与 stale hops 无绝对阈值，只用浓度不增 作单调约束，相关结论见 9.4.4 节（迁移的硬约束）。



Q3 五类缺陷化合物在生成侧与真实同风格侧的越阈率对比（OAV>1 的比例）。DMS/Diacetyl/4VG 用 8.xlsx 绝对阈值；trans-2-nonenal 与 Stale hops 无阈值，仅以浓度不增作单调约束（图中标注）。可见生成侧 DMS 与 Diacetyl 的越阈率系统性高于真实同风格，属必须披露的分布偏移。

8.4.4 负结果三：只能“部分迁移”

Pils/Lager → Tripel 的迁移在 11 个样本上全部满足硬约束（缺陷浓度不增、逐列训练支撑、非负）：`max_defect_violation_raw = 0.0`、`max_box_violation_raw = 0.0`，判定阈值 10^{-9}，且求解用解析投影兜底、

不依赖 SLSQP 的成功标志（源 `outputs/q3/transfer_report.json` 的 `feasibility` 段）；`defect_violation_rate` 与 `transfer_feasible_rate` 见表 20。早期运行曾报告 7.9×10^{-10} 的数值残差，不是当前权威值。但风格判别只把 6/11 个迁移后样本判为 Tripel，`transfer_tripel_hit_rate` 为 0.5454545454545454。原因在迁移报告（`outputs/q3/transfer_report.json`）中给出：DMS 与双乙酰是区分 Tripel 与 Pils/Lager 的强判别维度，而硬约束 禁止它们上升，于是“完整变成 Tripel”与“缺陷不恶化”在本数据上部分冲突。迁移确实把样本向 Tripel 质心 拉近（到质心的平均距离由 14.31 降到 9.48，全部 11 个样本都更近，均为开发产物），但分类器命中受约束限制。因此本文只写“部分向 Tripel 质心迁移”，不写“转为 Tripel 风格”，也不把它解释为可实现工艺收益——迁移是 数据空间中的约束投影，其反事实对照（`unconstrained_style_mean`）会产生缺陷恶化，只用于量化冲突代价。

8.4.5 条件 VAE：模式坍塌

条件 VAE（`EXP-0023`）的多样性比为 0.12137449372971756，低于预注册的可采纳阈值 0.5，因此不可采纳：它生成的样本集中在风格均值附近，风格命中率（0.7948245614035088）虽不低，但样本几乎没有多样性。这一族不进入最终选择，但其分数完整保留在表 20，供读者判断“选择是否依赖可采纳性 判据”。

8.4.6 感官画像的版本

生成谱的 50 维感官画像由 Q1 锁定模型前向映射得到。`EXP-0024` 记录的是占位映射器版本的画像秩相关（`profile_spearman_placeholder` = 0.4073149259703881），`EXP-0030`

换用 Q1 交付版映射后为 0.934437775110044（profile_spearman_delivered）。两版差异说明 画像对前向映射器敏感；论文引用画像一致性时必须标注版本，不能用占位版数字冒充交付版。

8.5 失败与未完成项

表 22 列出有代表性的失败实验（全部为台账记录，失败码与原因取自实验目录的 result.json 与日志）。

表 22 有代表性的失败与取消实验（台账记录）

实验	失败码与直接原因	对结论的影响	修正
EXP-0002	非零退出：2.csv 原始条件数为无穷大（矩阵近奇异），指标被拒	该次图结果不可用；暴露 2.csv 非正定	改报绝对值/重算条件数，增加秩与负特征值诊断
EXP-0004	无输出：退出码 0 但只在标准输出打印指标，未写 metrics.json	指标未入账，不能作证据	统一走契约写入
EXP-0005	无输出：契约探针向指标接口传字符串被具名拒绝（探针预期行为）	证明运行器只接受有限数值	结构化信息改走输出通道
EXP-0008	无输出：生成评估把指标打印到标准输出，未调用写入接口	问题三首轮评分不可入账	重写为契约调用，登记为新实验
EXP-0010	非零退出：嵌套输出含 NaN（某风格仅 1 个样本，能量距离无定义）	单样本风格的能量距离不可用	跳过并显式标注
EXP-0014	非零退出：内层选参时对固定超参族的候选列表为空，报类型错误	该次融合未锁定	固定超参族跳过内层选参
EXP-0016	非零退出：Q2 单变量基线脚本未完成契约化	Q2 基线未入账	由选择阶段开发运行替代，待补登记
EXP-0017	已取消（cancelled）：与 EXP-0014 相同的融合候选，重跑前撤销	无结论	由 EXP-0025 与补登记的 EXP-0029 承担

除实验失败外，以下**未完成项或方法局限**同样必须列明，且都不能写成“已验证”：

1. **分级标定不可辨识**：`4.csv` 的变换未知、列方差不为 1，分级只能依赖显式规则；P1–P4 的 QWK 跨度 0.31–0.49（表 16），说明分级结论对假设高度敏感，真实等级准确率不可评估。交付主表用 P2 是为满足题面 “0–6 分制” 的量程要求（P1 只覆盖 0–3、93.3% 落在等级 1），不是因为它更准。
2. **`2.csv` 非正定**：数值秩 226/231、5 个负特征值，不能直接求逆；M3 因此改用收缩精度矩阵估计（主口径 Ledoit–Wolf；开发期 glasso 口径曾因并列 artifact 在 41/50 维给出相同 Top-3，已修正）。
3. **LOD/2 删失**：755 个单元格是 “低于检出限” 的替代码，低浓度端不可作绝对量解释，OAV 低端被系统性抬高。
4. **Q2 Top-3 不可辨识**：登记版跨方法 Jaccard 均值 0.1867、仅 1/50 维达到 0.50，预注册命中率 0.0972；仅 14/150 席位满足 bootstrap 频率 $\geqslant 0.80$，且稳定性只有 B=100 快速代理，完整 B=300 未落盘。
5. **Q3 未超基线**：主候选的分布拟合指标与基线持平或略差（表 20），风格命中率饱和，缺陷越阈率偏移（表 21），迁移只部分成功。
6. **独立复跑失败**：`VAL-0012` 判 FAILED（见 9.7 节），其根因是评估脚本的共享产物与种子传递缺陷，不是 “随机波动”。
7. **`EXP-0029` 的独立复跑未执行**：四路融合备选的 leakage、split-integrity、holdout-metrics、baseline-compare 四项已通过，但 `independent-rerun` 两次因计算槽竞争（`EXP-0038`/`EXP-0042`）未能启动；因此它只能作为 备选报告，不能升格为最终方案。
8. **FIG-0001 为永久性记账瑕疵**：该图登记后因重绘导致文件哈希不一致（登记 6dee43f5…，当前 17123fbc…），旧字节不可恢复；正文**不使用**该图，交付以同一幅图的 FIG-0013 为准。该条会使 `delivery.check` 一直带 一条 figure STALE，属已知且不可修复的记账缺陷。
9. **`West Flanders ale` 无留出证据**：主划分留出集缺该类，相关结论只能用训练集描述。

8.6 验证状态

表 23 汇总各问的验证记录（只写台账真实状态；`passed` 且未过期才可称 “验证通过”）。

表 23 验证记录与状态（台账）

小问	检查类型	验证 id	实验	结果
共同	划分完整性	`VAL-0001`	`EXP-0003`	passed
共同	泄漏	`VAL-0002`	`EXP-0003`	passed
Q1	泄漏 / 划分完整性	`VAL-0003` / `VAL-0004`	`EXP-0007`	passed（历史版）
Q1	独立复跑	`VAL-0005`	`EXP-0012`	passed

小问	检查类型	验证 id	实验	结果
Q1	留出指标复算 / 划分完整性 / 泄漏 / 独立复跑	VAL-0007 / VAL-0008 / VAL-0009 / VAL-0010	EXP-0015	passed
Q3	泄漏	VAL-0011	EXP-0022	passed
Q3	独立复跑	VAL-0012	EXP-0024	**FAILED**（见 9.7）
Q1	留出指标复算 / 基线对比 / 泄漏 / 划分完整性 / 独立复跑	VAL-0013 / VAL-0014 / VAL-0015 / VAL-0016 / VAL-0017	EXP-0025	passed
Q2	独立复跑 (bootstrap)	—	—	未执行（稳定性实验未完成登记）

8.7 不可复现验证的处置：VAL-0012

VAL-0012 是对 EXP-0024 的独立复跑（随机实验，3 次，容差 0.05）。结果判 **FAILED**。逐项比较显示：

- gen_style_fidelity 完全复现（原值 0.994，三次复跑均为 0.994，差 1.1×10^{-16}）；
- 但 profile_spearman_placeholder（同时被写成 r2_50dim）**未复现**：原值 0.4073，三次复跑为 0.4073 / 0.8935 / 0.8935（均值 0.7315，极差 0.3241），远超 0.05 的容差。

根因不是随机波动，而是**评估脚本把种子固定写死、并读取了会被复跑进程重写的共享产物**：脚本不读取环境变量 MODELING_SEED，复跑目录里的画像映射器版本因此与主实验不同（一个用占位映射器、一个用 Q1 交付版映射），于是同一份生成谱得到两个不同的画像秩相关。这是“实现不确定性”而非“随机实验的 seed 敏感性”，所以不能用“随机实验本来就会波动”来解释 FAILED。处置如下：

1. 该验证**保持 FAILED 记录**，不得删除或改写为通过；本文任何“Q3 已验证”的表述都不成立。
2. 已登记 EXP-0030 作为“Q1 交付版画像”的再评估(profile_spearman_delivered)，但它**不是**一次新的 独立复跑；新的 independent-rerun 必须在评估脚本修好之后用新实验编号重新登记。修法有三条：① 读 MODELING_SEED 并在实验目录内落盘随机状态；② 画像映射器版本写入 outputs 而不是共享路径，复跑不得 覆盖主实验的产物；③ 复跑前后校验输入产物的 sha256，不一致直接判失败而不是继续比较。
3. 在修复并重新验证之前，问题三的结论只按“真实执行”等级引用（表 25），不能升格为“验证通过”。

8.8 预注册与实际结果的偏离

本文的比较判据在查看结果之前登记（见 2.6 节），因此必须逐条交代“登记时怎么判、实测是什么、结论如何降级”。表 24 是这张偏离清单；凡是判据未达到的，结论按右列降级，**不调整阈值**。

表 24 预注册判据与实际结果的偏离及结论降级

预注册判据	实测	结论的降级方式
Q1 候选须优于常数基线	候选 50 维 R^2 均值明显高于基线（表 14、表 15）	不降级；Q1 是三问中唯一“执行 + 验证”都齐的
Q1 分级 QWK 可作等级准确率	真实 0–6 等级不存在；P1–P4 的 QWK 0.31–0.49，P1 仅 13/50 维真实锚定	降级为“标定敏感性”，不报告分级准确率
Q2 跨方法 Jaccard 均值 $\geqslant$ 0.50	登记版 0.1867（reviewer 独立复算的 pair-level 口径为 0.2196），仅 1/50 维达标	降级为“共识候选 + 可信度分级”，不给确定性 Top-3
Q2 bootstrap 入选频率 $\geqslant$ 0.80 视为稳定	稳定性实验未完成登记	不给任何席位标“稳定”
Q2 与预注册风味化学期望一致	命中率 0.0972（14/144 席位）	作为负结果披露（多数期望未被命中）
Q3 主模型应优于基线 (ED/D_ref)	主模型 0.12643 vs 基线 0.12618	降级：只支持约束可行性与可解释性，不支持分布拟合优势
Q3 缺陷“五类全部不恶化”	只有三类有绝对阈值；生成侧 DMS/双乙酰越阈率系统性高于真实	降级为“三类绝对阈值 + 两类单调代理”，并声明生成缺陷有偏
Q3 跨风格迁移应达到目标风格	硬约束 11/11 满足，但风格判别仅 6/11	降级为“部分向目标风格质心迁移”，不写“转为目标风格”

8.9 台账四类事实对照表

表 25 按四个等级逐小问汇总当前状态。“验证 = 部分”表示该问已有 passed 的检查，但仍有未执行或 FAILED 的 检查；不得把“部分”读成“通过”。

表 25 台账四类事实对照表（计划 / 真实执行 / 验证通过 / 被选中）

小问	已计划	真实执行	验证通过	被选中
Q1	模型与 VP 已登记	EXP-0025 succeeded (EXP-0015 为基线)	部分：EXP-0025 的五项检查 VAL-0013–0017 全部 passed (5/5，含 independent-rerun)；EXP-0015 的 VAL-0007–0010 亦 passed	待 select (selectedModelId 为空)
Q2	模型与 VP 已登记	仅共表达图 EXP-0003 succeeded；Top-3 选择未登记为 EXP（仅开发运行）	部分：图结构经 VAL-0001、VAL-0002；稳定性与独立复跑未完成	无
Q3	模型与 VP 已登记	EXP-0022、EXP-0024（及 EXP-0030）succeeded	部分：VAL-0011 (leakage) passed；VAL-0012 (independent-rerun) FAILED (1/2)	待 select

9 稳健性与敏感性

9.1 划分敏感性

主划分与分层划分的留出集有 92 个 beer 不同，且风格覆盖不同（21/22 vs 22/22）。因此所有主实验在分层划分上 复核一次，两栏并列报告。这一设计不能消除偏差，但能让读者看到 “结论是否依赖某一条划分”。特别地，`West Flanders ale` 在主划分的留出集中完全缺席，该风格的一切结论只能用训练集描述，并标注 “无留出证据”。

9.2 标定敏感性

分级标定的敏感性是本数据上最大的不确定性来源：P1 主划分只锚定 13/50 维、分层锚定 15/50 维，其余维度靠 参数平移；P2/P3/P4 又各自对应不同的分布假设。四套口径给出的 QWK 与等级分布会有系统差异，本文要求 **四套口径并列报告**，不挑一套作为 “准确

率”。若四套口径下“候选优于基线”的排序不一致，则结论只能写“在部分标定口径下更优”，不能写“分级更准”。

四套口径的 QWK 与分级误差已在 9.2 节（表 16）按开发运行的产物报告；由于这些数值尚未登记为实验指标，它们只用于说明敏感性量级，不用于任何“哪套口径更好”的排序。

9.3 缺失与尺度处理敏感性

缺失处理与尺度协调各有替代口径：插补用 kNN 与迭代插补替代中位数；尺度协调用“不做协调”（协议字面版）替代主口径。两种替代都在训练折内拟合，选型与评估流程不变。若替代口径下候选的 OOF 排名发生实质变化，说明结论对预处理敏感，应在结论中标注。这里有一个必须写清的**预处理口径对照**（15 折 OOF，开发运行，来源 `outputs/protocol/decisions_log.md` 与 `REPRODUCE.md`，未登记为实验）：如果把 33 个已验证线性列（跨度约 10^{-9}–10^{3}）与 37 个 $\log_{10}$ 列**直接混在一起做折内标准化**（不做尺度协调），15 折 OOF 的 50 维均值会崩溃到 -0.9301 ± 1.1423，39/50 维为负；崩溃主因是**混合尺度**，不是 winsorize 本身—— 尺度协调、1%/99% 截尾、标准化后裁剪 ± 8 三条路径几乎等价（OOF 分别为 0.1987 / 0.2002 / 0.1997）。这条证据支持 6.2 节把“尺度协调”放在预处理链第一步，也说明本题的预处理不是为了刷分，而是为了避免一个 可复现的数值崩溃。删失处理同样有敏感性：`oav.csv` 按标定浓度计算（非检出记 0），若改用 LOD/2 代码，低端 OAV 会系统性抬高约 2 倍，缺陷越阈率随之变化，因此问题三的缺陷结论必须声明口径。

9.4 模型与随机性敏感性

问题一的候选族在 15 折 OOF 上比较，重复间标准差用来判断族间差异是否超过噪声；若两个族的 OOF 差异小于 其重复间标准差，本文不宣称其中一个更优。问题二的稳定性只有 B=100 快速代理（`top3_stability`），后者只作方向性参考。问题三用多个种子（含主种子 42）重复生成，报告命中率与能量距离的相对极差；同时检查 同种子逐值复现，以区分“随机性”与“实现不确定性”。

9.5 消融与稳健性（开发运行，未登记）

以四路融合为基准（训练内 OOF 的 50 维 R^2 均值为 0.25451158623613646，台账值），在开发运行（`outputs/q1/ablation_sweep.csv` 与 `ablation_noagg.csv`，**未登记为实验**）中做了四组消融：

表 26 四路融合的消融结果（开发运行，未登记为实验指标）

配置	特征数	训练内 OOF（50 维 R^2 均值）	相对基准
基准：231 特征（四路融合）	231	0.25451	—
只用 37 个已验证 $\log_{10}$ 列	37	0.25525	+0.00073

配置	特征数	训练内 OOF（50 维 R^2 均值）	相对基准
去掉 5 个化合物聚合列	226	0.25639	+0.00187
折内中位数插补改为 KNN(k=5)	231	0.25693	+0.00242
231 特征 + 43 个 OAV 特征	274	0.26203	+0.00751

两个反直觉的发现值得单列：

1. **只用 37 个已验证的 $\log_{10}$ 列，就能复现 231 列模型的水平**（0.25525 vs 0.25451）。这说明 161 个 `unverified` 尺度列几乎没有增量信息——这是**数据限制**（尺度不可验证、只能按序数使用）的结果，不是 特征工程的失败；反过来说，也提示 “231 维” 这个数字本身高估了有效信息量。
2. **去掉 5 个聚合列不降反微升**（0.25639 vs 0.25451）。聚合列与底层化合物高度冗余，是 “同一物理量的两种 表达”；这解释了为什么它们的高相关**不是泄漏通道**：它们不引入目标信息，只是把已有化合物的加和再写 一遍。消融结果支持保留它们（差异在噪声量级），但不应把 “含聚合列” 当作模型优势。

稳健性方面，3 组预登记扰动（只用 $\log_{10}$ 列、KNN 插补、加 OAV 特征）下 OOF 的极差为 0.00678，小于 预注册阈值 0.05；3 组扰动都**没有翻转** “融合优于单模 ExtraTrees” 的结论（来源 `outputs/q1/robustness.json`）。但必须注明：`ROB-0001` 稳健性计划**未在台账执行**，上述数字来自开发运行，因此本节结论只算 “方向性证据”，不能写成 “稳健性验证通过”。

9.6 图阈值敏感性

问题二在 $\tau \in \{0.20, 0.25, 0.30, 0.35, 0.40, 0.45, 0.50\}$ 的网格上重建图并报告边数、模块数与模块度，用以说明 “模块结构是否依赖单一阈值”。敏感性结果落盘在 `outputs/q2/graph_threshold_sensitivity.csv`。需要强调的是：阈值敏感性只说明图结构稳定与否，**不改变** Top-3 的选择（选择用全矩阵，不用阈值图），两者不得混用。

10 模型评价与局限

10.1 优点

1. **先核实、后建模**：把题面与数据的 12 处不一致作为前置环节，避免在错误坐标系里建模；所有数据事实 可复算，实验指标全部可回溯到台账。
2. **折内纪律**：插补、截尾、标准化、选参、标定参数一律只在训练折拟合；留出集只用一次；候选与基线共享 同一划分与同一预处理。
3. **区分四类事实**：计划、执行、验证、选中四种状态在论文中分开表述，失败实验如实保留，不把 `succeeded` 写成 “已验证”。
4. **关联与因果分开**：问题二只声明关联，问题三的迁移只声明 “在约束下的成分调整”，不外推为工艺收益。

5. **可复现**：解释器路径、依赖版本、随机种子、数据与划分的哈希由台账与复现说明固定；同一代码可重跑。

10.2 局限

1. **没有真实的 0–6 评分标签**：`3.xlsx` 是空白评分卡，`4.csv` 是未知变换的连续值，因此“分级准确率”不可评估，只能报告标定敏感性；交付主表 P2 与变体 P1 都只是显式规则，不是正确答案。这是本题最大的 认识论限制。
2. **`4.csv` 的变换不可辨识**：列均值近 0 但方差不齐，无法从数据反推其标准化方式；P1 依赖外部阈值锚点，而阈值本身是平均阈值，存在个体与基质差异。
3. **混合尺度与不可验证列**：161 列尺度不可验证（145 列含负值、142 列共享地板值），只能按序数型使用，不参与绝对量解释；37 个 `log10` 列的低端是 LOD/2 删失替代码（755 格），低浓度端不可作绝对量解读。
4. **缺失非完全随机**：虽然风格与缺失无显著关联（$p \approx 0.34$），但目标均值在缺失行与完整行之间有可见 差异，MNAR 的可能性不能排除；插补偏差无法从数据内部估计。
5. **主划分未分层**：留出集缺 `West Flanders ale`，21/22 类覆盖；分层版最小类 `Faro` 在留出集只有 1 个 样本，小类结论只能作描述，不能声称分布被精确刻画。
6. **样本量小**：250 个样本、22 个风格、231 个特征，问题三的每风格协方差不可估，只能共享协方差；问题二的 20 次 bootstrap 的蒙特卡洛误差约 ± 0.09。
7. **没有外部验证集**：所有结论都在同一数据集的两个划分上得到，缺少独立来源的外部验证；`7.csv` 虽为外部 佐证，但它是 Ratebeer 侧派生数据、且与目标同源，不能替代独立验证。
8. **OAV 的单位前提不可内部验证**：标定浓度表没有单位列，“cal 数值单位 = 阈值表单位”这一前提只能由外部 常识支持，无法由数据内部证明。
9. **五类缺陷中只有三类可算绝对阈值**：trans-2-nonenal 与 stale hops 的阈值缺失，其“不恶化”只能用浓度 单调性代理，证据强度低于另外三类。
10. **`2.csv` 与重算矩阵不完全一致**：列中位数填补口径下最大绝对差约 0.048（成对完整样本口径下为 5.0×10^{-16}），因此 `2.csv` 只能作结构先验，不能当逐格真值。
11. **`2/5/6.csv` 都是同数据重算，不是外部数据**：用 `6.csv` 核对 Top-3 属于循环验证，其一致性数值不构成 外部效度证据（`CLAIM-0006`）；本文没有任何独立外部验证集。

10.2.1 数据边界：每一处边界影响哪条结论

上述局限不是“套话列表”，每一处边界都对应一条被限制的结论（表 27）。

表 27 数据边界与受影响的结论

数据边界	事实	受影响的具体结论
161 列尺度未验证	145 列含负值、142 列共享地板值 -1.8178	“浓度/OAV” 只对 70 列成立；若 Top-3 命中 `unverified` 列，只能作序数关联，不能作剂量解释
755 格 LOD/2 删失	低端是 “最小正浓度/2” 的替代码	OAV 低端与缺陷越阈率在阈值附近对替换规则敏感；低浓度结论只作趋势
`4.csv` 变换未知、非单位方差	列标准差 0.37–0.86	分级标定的位置/尺度不可辨识，QWK 只能作敏感性
主划分未分层	留出集缺 `West Flanders ale`（21/22 类）	该风格的一切结论无 holdout 证据
小类样本极少	Kriek 10、Lambic 11、Faro 3；留出 1–3	逐风格保真度与能量距离在小类上不可下结论（置信区间极宽）
`2.csv` 非正定	数值秩 226/231、5 个负特征值	不能直接求逆；M3 用收缩精度矩阵（开发期 glasso 口径曾出现 41/50 维并列退化）
`6.csv` 为同数据重算	与独立重建最大差 6.7×10^{-16}	一致性数值（表 18 的 `prior_spearman_mean`）是循环验证，不是外部效度
标定浓度表无单位列	—	OAV 的单位前提不可由数据内部验证
`5.csv = Spearman(4.csv)`	最大差 6.1×10^{-16}	感官维度间结构不能当独立证据

11 结论与建议

11.1 结论

1. **数据层面**：附件与题面存在 12 处不一致（样本数、相关类型、矩阵维度、维度数、评分卡空白等）；`1.csv` 是混合尺度表（37/33/161 列），含 755 个 LOD/2 删失替代码与 73 个真实缺失；`4.csv` 是未知变换的连续值 而非 0–6 分。这些结论由审计脚本复算，先于任何模型结论成立。
2. **问题一**：三路等权融合（`EXP-0025`）在留出集上的 50 维 R^2 均值明显高于常数基线（原值见表 14 与 表 15），50 维中 43 维为正；该结果经包契约检查与 reviewer 的独立复算通过，是三问中唯一 “执行 + 验证” 都齐的。分级结果因缺真实等级标签，只

能作为标定敏感性的证据，不得解读为等级准确率；dms/diacetyl 两维的 R^2 也不能解读为“测出了缺陷”。

3. **问题二**：共表达图在 $\tau = 0.3$ 下包含 3918 条边、7 个模块，但 2.csv 数值秩为 226、含负特征值，不可直接求逆。Top-3 的跨方法一致性远低于预登记阈值（表 18：Jaccard 均值 0.18666666666666668，仅 1/50 维达标）、预注册风味化学期望命中率为 0.09722222222222222，因此本文交付的是“共识候选 + 可信度分级”，而不是确定性的关键因素清单；且 2/5/6.csv 均为同数据重算，一致性核对属于循环验证，不构成外部效度。
4. **问题三**：主候选的分布拟合未优于更简单的基线（表 20），风格命中率在锚定后饱和；生成侧缺陷越阈率 系统性高于真实同风格（表 21）；迁移在 11/11 个样本上满足硬约束，但风格判别只部分命中，只能写“部分向目标风格质心迁移”。VAL-0012 独立复跑 FAILED，因此问题三目前只达到“真实执行”，尚未“验证通过”，也不能被选为最终方案。

11.2 对实践的建议

1. **把 OAV 作为配方调整的量纲**：以阈值归一化的活度值比原始浓度更适合跨化合物比较；但低浓度端受 LOD/2 删失影响，配方建议应以实测验证为准，不能只用模型输出。
2. **优先补齐“未验证尺度”列的单位**：161 列中多数只能按序数使用，若在工艺上有意义，应先做标准品校准，再谈定量优化。
3. **分级评分卡需要真实标注**：若要评估 0–6 分级准确率，必须采集真实评分（哪怕是部分样本），否则只能 做“标定敏感性”分析。
4. **风格迁移不要承诺工艺收益**：本文的迁移是数据空间中的约束投影，不是发酵实验；若要用于酿造，需要 以工艺试验验证方向与幅度。

11.3 后续工作

1. 在获得真实 0–6 评分后，用同一套折内协议重估分级模型，届时 QWK 才可读作分级准确率。
2. 扩大样本（尤其 Faro、Scotch、Christmas 等小类），使每风格协方差可估，减少共享协方差的偏差。
3. 对 161 个未验证列做标准品校准，把序数型特征升级为浓度型特征。
4. 用外部独立数据集（而非同源 7.csv）做外部验证，检验 Top-3 与生成模型的可移植性。

参考文献

[1] Meilgaard MC, Civille GV, Carr BT. Sensory Evaluation Techniques (5th ed.). Boca Raton: CRC Press, 2016.

[2] ISO 4121:2003. Sensory analysis — Guidelines for the use of quantitative response scales. Geneva: International Organization for Standardization, 2003.

[3] ISO 6658:2017. Sensory analysis — Methodology — General guidance. Geneva: International Organization for Standardization, 2017.

[4] Fechner GT. Elemente der Psychophysik. Leipzig: Breitkopf und Härtel, 1860.

[5] Stevens SS. On the psychophysical law. Psychological Review, 1957, 64(3): 153–181.

[6] Grosch W. Evaluation of the key odorants of foods by dilution experiments, aroma models and omission. Chemical Senses, 2001, 26(5): 533–545.

[7] Breiman L. Random forests. Machine Learning, 2001, 45(1): 5–32.

[8] Breiman L. Bagging predictors. Machine Learning, 1996, 24(2): 123–140.

[9] Meinshausen N, Bühlmann P. Stability selection. Journal of the Royal Statistical Society: Series B, 2010, 72(4): 417–473.

[10] Cohen J. Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit. Psychological Bulletin, 1968, 70(4): 213–220.

[11] Benjamini Y, Hochberg Y. Controlling the false discovery rate: A practical and powerful approach to multiple testing. Journal of the Royal Statistical Society: Series B, 1995, 57(1): 289–300.

[12] Efron B, Tibshirani RJ. An Introduction to the Bootstrap. New York: Chapman & Hall, 1993.

[13] Kingma DP, Welling M. Auto-encoding variational Bayes. In: International Conference on Learning Representations (ICLR), 2014. arXiv:1312.6114.

[14] Sohn K, Lee H, Yan X. Learning structured output representation using deep conditional generative models. In: Advances in Neural Information Processing Systems (NeurIPS), 2015: 3483–3491.

[15] Székely GJ, Rizzo ML. Energy statistics: A class of statistics based on distances. Journal of Statistical Planning and Inference, 2013, 143(8): 1249–1272.

[16] Clauset A, Newman MEJ, Moore C. Finding community structure in very large networks. Physical Review E, 2004, 70(6): 066111.

[17] Langfelder P, Horvath S. WGCNA: an R package for weighted correlation network analysis. BMC Bioinformatics, 2008, 9: 559.

[18] Friedman JH. Greedy function approximation: A gradient boosting machine. Annals of Statistics, 2001, 29(5): 1189–1232.

[19] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees. Machine Learning, 2006, 63(1): 3–42.

[20] Wold S, Sjöström M, Eriksson L. PLS-regression: A basic tool of chemometrics.

Chemometrics and Intelligent Laboratory Systems, 2001, 58(2): 109–130.

[21] Rubin DB. Inference and missing data. Biometrika, 1976, 63(3): 581–592.

[22] Little RJA, Rubin DB. Statistical Analysis with Missing Data (2nd ed.). Hoboken: Wiley, 2002.

[23] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices. Journal of Multivariate Analysis, 2004, 88(2): 365–411.

[24] Strobl C, Boulesteix AL, Zeileis A, Hothorn T. Bias in random forest variable importance measures: Illustrations, sources and a solution. BMC Bioinformatics, 2007, 8: 25.

[25] Pedregosa F, et al. Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 2011, 12: 2825–2830.

[26] Harris CR, et al. Array programming with NumPy. Nature, 2020, 585: 357–362.

附录 A 复现说明

项目的可复现性由三部分固定：解释器与依赖、数据与划分的哈希、随机种子。

1. **解释器**：项目绑定的 Python 解释器路径写在 `contest.yaml` 的 `runtime.python`；交付包中的 `README_REPRODUCE.md` 给出绝对路径与依赖版本。
2. **数据**：`data/raw/` 保留原始附件，导入副本核对 SHA256；清洗后的主表为 `data/clean/model_table.csv`（$250 \times 284 = 3$ 键 $+$ 231 特征 $+$ 50 目标），由脚本生成，正文不抄写哈希。
3. **划分**：主评估 `data/splits/SPLIT-0002/`（random-holdout，0.2，seed 42），分层稳健性 `data/splits/stratified/`；两者都提供 `assignment.csv`，不得手工改动。
4. **种子**：问题一的重复分层折与模型种子为 42；问题二的 bootstrap 种子为 42 加重采样序号；问题三主种子 为 42，另有多个对照种子。所有种子写在产物中。
5. **一键复现**：`report/build.sh` 从渲染稿生成 TeX 并编译 PDF；实验按台账实验编号重跑，命令与产物见 附录 B。

附录 B 代码与数据清单

表 B-1 代码与产物清单

环节	脚本	主要产物
审计	`src/00_audit.py`	`audit.json`
尺度与 OAV	`src/02_scale.py`	`scale_report.json`、`oav.csv`
清洗	`src/03_clean.py`	`data/clean/*`、字段字典

环节	脚本	主要产物
主表构建	src/07_model_table.py	model_table.csv、fields_model.json
划分	src/04_split.py	stratified/*、split_summary.json
维度对齐	src/05_dim_map.py	dim_map.csv
标定	src/06_calibration.py	grade_calibration_*.csv
问题一	q1_data.py、q1_models.py、q1_final.py	outputs/q1/*
问题二	q2_graph.py、q2_select.py、q2_stability.py	outputs/q2/*
问题三	q3_models.py、q3_generate.py、q3_transfer.py、q3_eval.py	outputs/q3/*

附录 C AI 使用说明

本文在数据核实、代码实现、实验台账管理与文字整理环节使用了 AI 编程助手（DeepSeek Harness 会话内的智能体），用途包括：生成与修改分析脚本、撰写实验登记信息、整理论文结构。所有结论性数字均来自项目台账中的真实实验 记录，由渲染工具从台账解析后写入正文，不由 AI 直接抄写；数据事实由审计脚本复算。实验失败、检查未通过与 未完成项均在正文中如实标注，未以 AI 生成内容替代证据。