目录

1 啤酒化学成分、感官映射与条件生成：实战整改审计草稿 1

1 啤酒化学成分、感官映射与条件生成：实战整改审计草稿

> **DRAFT，不能作为通过质量验收的竞赛终稿**。本稿由工程整理程序根据竞赛独立副本的真实台账与复算文件生成；模型已自主修订目标契约并完成两个隔离训练实验，但在工具 JSON 格式错误后停止。后续独立模型审查未执行。原论文完整保存在 `report/history/pre-practical-repair/`，原实战项目未被改动。

1.1 摘要

本项目包含 250 个啤酒样本、231 个化学特征及 50 个感官维度。读题与附件核对显示：化学数据混合了线性与对数尺度，感官评分卡为空白，现有感官表不能被直接解释成具有独立金标准的 0–6 等级标签。我们分别审计多输出预测、关联稳定性和条件生成，不将三者混作同一个 R^2。

Q1 已选模型 `MODEL-0022 / EXP-0025` 的历史 50 维平均留出 R^2 为 0.220579。更强的 `EXP-0029` 存量预测，经按 beer×dim 对齐全部 2500 个测试单元格后，逐维 R^2 的算术平均为 **0.253574**，`overall` 维仅 **0.009210**。该审计只能证明存量文件中的指标一致，不能补成历史模型的独立复跑证明，也没有据此自动改选模型。

Q2 的实际候选已是 `MODEL-0032 / EXP-0041`，不是“无候选”。它的平均 Jaccard 为 0.186667，预登记命中率为 0.097222，仅 1/50 个维度的 Jaccard 达到 0.5。旧产物中以 r2 命名的同值字段实际是集合重合度，本稿不把它解释为预测 R^2。

Q3 的 `MODEL-0029 / EXP-0036` 仍存在映射器依赖不完整、历史复跑失败与较弱的分布拟合证据。留出集历史被反复用于模型判断，不能通过重新划分或更换 split ID 恢复为未见数据。因此本稿如实保持草稿。

1.2 问题定义与数据边界

三个目标契约已经分别绑定 Q1/Q2/Q3。Q1 是附件所给感官分数的同期估计，Q2 是同源数据上的关联分析，Q3 是带约束的算法生成。它们分别使用完整的 50、50 和 231 列目标集合。感官分数的变换来源仍须独立推导审查；不声称未来预警、因果效应或真实等级准确率。

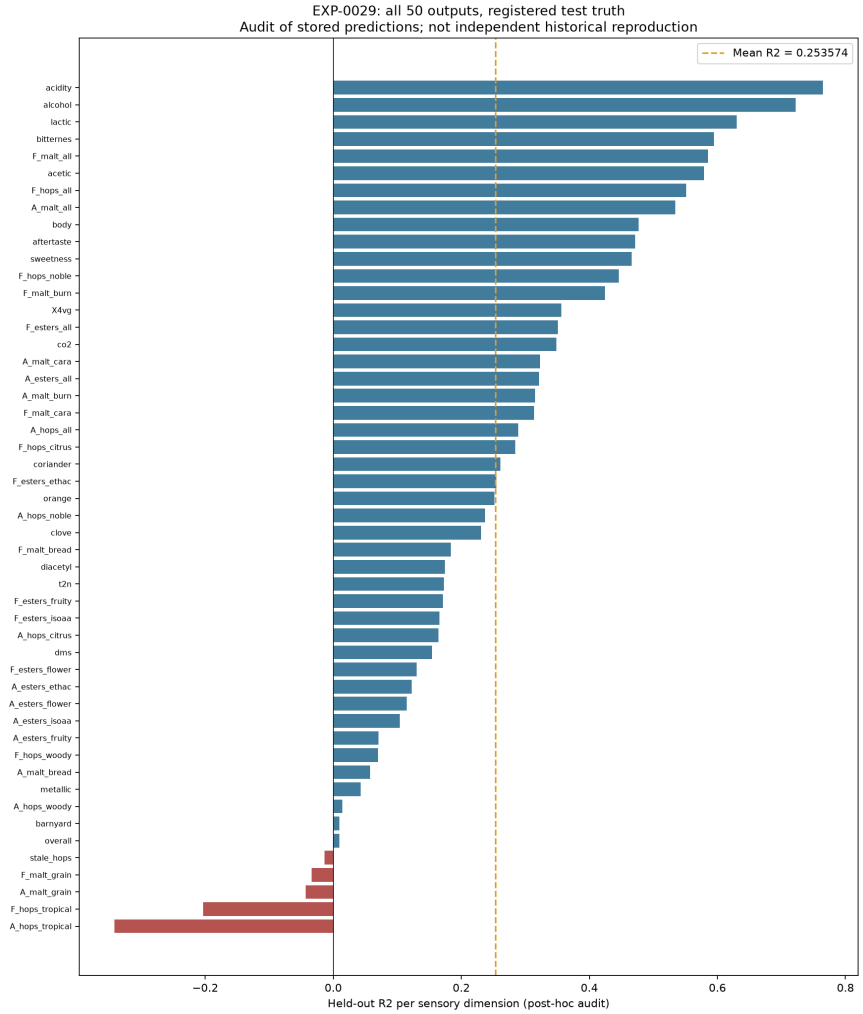
附件 2、5、6 中的矩阵来自同一批样本的计算，不构成额外独立验证集。去掉五个聚合化学列后边际贡献接近零，只能说明冗余程度，不能证明不存在计算血缘泄漏。原始资料、失败实验和既有交付包均保留。

1.3 Q1：全部 50 维的存量预测复算

复算脚本是模型在本轮编写的 `src/q1_recompute_exp0029.py`。工程师通过单独 wrapper 和公开 `modeling_data run-script` 完成执行登记。它读取 `EXP-0029/predictions_long.csv` 的 test 行，与 `SPLIT-0002/test.csv` 的 beer×dim 唯一键连接，拒绝重复、缺失及多余键，并逐项核对嵌入真值。

核对项目	实际结果
测试样本数	50
目标数	50
连接单元格数	2500
50 维 R^2 算术平均	0.253573746847
50 维 R^2 中位数	0.244621884536
overall 单维 R^2	0.009210149437
逐维 MAE 算术平均	0.334084593860
逐维 RMSE 算术平均	0.459240459392
嵌入真值与登记真值最大差	0

逐维明细见 `report/analysis/practical-q1-audit/per_dim_recompute.csv`。单列 overall 的复算不能替代这个 50 维结果；pooled R^2 也不是逐维平均 R^2。本稿采用逐维算术平均口径，不在多个聚合口径中挑选好看的数字。



全部 50 维 R^2 的事后审计

1.3.1 新的隔离训练证据

本轮模型自主编写 `src/q1_trainonly.py`，在仅含 200 条训练记录的 OS 隔离环境中完成五折 OOF。`EXP-0049` 的初次执行因常数基线处理空特征时出现 TypeError 而失败，失败日志保留；模型修复脚本后执行 `EXP-0050/0051`。

新实验	方法	50 维平均 OOF R^2	逐维平均 MAE	范围
EXP-0050	折内均值基线	-0.008650	0.419159	训练集 OOF
EXP-0051	折内 Ridge	0.176100	0.363366	训练集 OOF

这些实验是真实执行结果，但缺少完整目标绑定与后续审查，不能据此宣称质量闭环通过。训练 OOF 与旧留出成绩的样本范围、选择过程不同，不进行跨口径排名。已有留出集污染不因这些新实验而消失。

1.4 Q2：关联分析与集合稳定性

实际候选 EXP-0041 的平均 Jaccard 为 0.186667，中位数 0.150000；稳定席位为 14/144，命中率 0.097222。这支持“当前方法之间的关键变量集合一致性有限”，不支持强稳定性或因果解释。

新插件分别定义 Top-k Jaccard、重采样入选频率和完整排序 Spearman。集合重合、入选频率与排序相关性是不同统计量。正式稳健性执行尚未完成，不能把已有未执行的预登记计划写成已完成；也不能把同源矩阵的一致当成独立复核。

1.5 Q3：约束满足、分布拟合与画像必须分开

当前选中 EXP-0036 的规则风格命中率为 0.994000，但这可能饱和，不能证明生成分布接近真实分布。Tripel 的能量距离比值为 0.12642884，未优于历史基线约 0.12618。迁移命中为 0.545455，对应约 6/11 个样本。

defect_violation_rate 为 0 只说明该实验定义的直接缺陷约束通过，不覆盖画像映射后的其他越阈指标。r2_50dim 在旧 Q3 文件中实际上被用于画像相关性，本稿不称其为 R^2。新原生检查将分布距离、数值约束满足率和训练参考群体画像 Spearman 分开计算；画像仍是代理模型一致性，不是真人喜好准确率。

历史 VAL-0012 等失败与上游映射器变化证据保留。没有完整冻结的历史源代码、辅助模块、模型 bundle 与标定依赖，无法补写过去的独立复跑成功。对未来新实验要求完整冻结、逐实验目录、固定种子复现，以及另行预登记的多种子稳健性。

1.6 验证、未通过原因与最终状态

本轮质量计划实际执行后：通过 15 项、失败 10 项、待语义复核 4 项、不适用 3 项、过期 1 项。存在 18 条阻塞记录，其中包含重复或额外计划项，不能误读为同样多的独立根因。

主要根因是：历史留出集复用超限；旧实验没有完整不可变依赖；Q1 分数变换尚未独立审查；已声明目标与旧 baseline 记录未绑定；三个稳健性计划没有有效执行；部分旧审查因实际对象变更而过期。Q2 已有候选，“Q2 无候选”不再是当前根因。

工程上可运行、质量检查通过、七检查点通过是三个分别成立的条件。终稿条件始终为 engineeringComplete AND qualityPassed AND checkpointsPassed，不是“已有 PDF”或“实验成功”。本项目保持 final=false，只能生成显式 DRAFT 包。

1.7 模型自主、工程辅助与费用边界

模型自主：修订三个目标契约、编写训练 OOF 脚本、修复一次真实失败、执行均值与 Ridge 实验、编写完整 50 维事后审计脚本。工程辅助：一致快照、预算接缝、执行审计 wrapper、生成本审计草稿与图、编译格式、运行质量检查和草稿打包。

模型在准备一次工具调用时输出了非 JSON 的占位变量，宿主返回 MALFORMED_RESPONSE。该次尝试未提供原生用量，因此已停止所有新付费验收；独

立模型审查、模型自主 claim/coverage/robustness/review 全闭环尚未完成。已确认累计 3,389,231 tokens，另有 1,056,768 tokens 请求预留未能结算，实际总量未知，保守上界为 4,445,999 tokens。未使用剩余预算继续重试。

1.8 复现与证据

原项目为只读来源；所有本轮整理发生在独立副本。先核验 `SOURCE-SNAPSHOT.json` 与输出审计 SHA，再在固定 Python 环境中运行审计 wrapper。训练实验从各自冻结源目录执行，必须使用登记种子和训练输入，不得读取原测试文件。不要直接运行旧生成脚本覆盖共享输出。

Q1 审计文件、公开 handler 回执、真实宿主模型工具回执、阶段费用账和完整质量报告随交付附上。本稿不是新的模型自主终稿，也没有通过改动台账、放松质量门或提高留出次数来制造成功。